

lirpa_forward_backward_fc_array.cpp를 CUDA로 재작성하기

CUDA 의 핵심

기본적으로 c++ 언어에서 GPU의 동작을 가능하게 한 것이 CUDA

그러다 보니 기본적으로 c 언어와 동일하고 CUDA 동작이 필요한 코드만 따로 바꾸어도 nvcc(NVIDIA C Compiler) 에서 컴파일 가능

그럼 lirpa_forward_backward_fc_array.cpp 에서 기본 틀을 가져와서 병렬 연산이 필요한 부분만

kernel 함수로 바꾸면 되지 않을까? (이 때 kernel 함수란 device, 즉 GPU에서 동작하는 코드를 의미)

⇒ 먼저 진입점 함수를 분석해보자

main

1. epsilon을 입력받음 ← 이때 시스템 호출 인자를 줄 수 있으며 eps의 값을 변경 가능
 - a. 개선 사항 : 여기에서 처음에 말씀하신 차원 수를 임의로 바꾼다거나 하는 기능을 추가하면 될 듯?
2. self_test_relaxations 호출
3. run_xor_demo 호출

self_test_relaxations 분석.....

← 사실 본 검증에서는 크게 관련없는 안정성 테스트용 코드라서 크게 흐름에 영향을 미치지 않음

중요한 건 run_xor_demo 인데

=====

하다가 뭔가 매우 복잡해서 일단 cpp 처음 코드부터 그대로 복붙하면서 배열 연산이 필요해보이는 곳을 파악하기로 했다.

mat_add 부터 배열을 통한 연산을 하고 있음 ← 포팅을 해봤다..

근데 이걸 mat_add는 한 두번 호출하는 것도 아니고 여러번 호출한다.
(메모리 할당, 해제가 여러번 일어남)

⇒ 비효율적이라 생각하는데 일단 최적화는 나중에 진행하기로 함

최종 포팅, 컴파일, 실행 검증 완료(동일하게 동작함)

=====

1차 진행 상황 보고 이후 (내가 해야 할 것,)

1. backward only mode의 재귀(recursive) 버전
2. backward only 의 loop 버전
3. ??? 뭐였더라

pruning 을 적용해서 (파라미터 수를 93%정도 제한함)

4. backward only 의 iteration 버전을 희소행렬로 만든 버전

최종 목표는 이 4가지를 cuda 프로그램으로 만들어서 돌려보는 것

+ 램다 같은 함수들을 rewrite 하는 discussion 이 필요함(교수님과)

=====

2주차 해당 과제를 받음

최광훈
안테나 선택 신경망은 Fully Connected 구조이고요.

Fully Connected Neural Network with 2 Hidden Layers and the Output Layer

Number of neurons of FCN. We assumed $N_I = 8$, $N_R = 1$. Thus the length of input vector is $N_R \times N_R = 256$.

layer index l	number of neurons
0(input)	$N^{(0)} = 256$
1	$N^{(1)} = 491$
2	$N^{(2)} = 491$
3(output)	$N^{(3)} = 16$

오후 5:08

최광훈
입력 $N^{(0)}=256$ 개 (16x16),
출력 $N^{(3)}=16$ 개

히든 계층은 2개인데, $N^{(1)}=491$, $N^{(2)}=491$ 이에요.

일단 한번 살펴보고 궁금한게 있으면 언제든지 바로 바로 질문하세요~

오후 5:09

최광훈
즉, crown 알고리즘의 입력으로 테스트 데이터 1개와 $\text{eps}=10^{-6}$ 으로 crown 알고리즘을 돌려서 16개 출력을 뽑는 것을 1차 목표로!

혹시 궁금한 사항이 있으면, 나한테 물어봐도 되고 또는 김송현 학생한테 물어봐도 됩니다~

오후 5:14

아마 my_lirpa.cu에 실제 신경망을 로드(기존에는 가상 신경망을 사용했음) 해서.. 16개 출력을 뽑는 것을 1차 목표로 하라는 말씀 같음

⇒ 새로운 crown_test.cu를 만들어서 작성

1. 모델 파일을 읽어올 때(로드) [CustomToLirpa.py](#)를 참조해 모델.bin 구조를 파악함
2. 새로운 FullyConnectedNetwork를 heap에 할당(트러블 슈팅 참조)해 읽어온 신경망을 로드
3. .Pickle로 되어있는 데이터셋을 CUDA로 읽어오기 위해 .bin 파일로 변환 (테스트 단계이므로 1개의 데이터셋 (입력 256개 1세트) 만 변환)
4. GPU에 신경망 로드(Memcpy) 및 CROWN 호출

그러다 GPU로 이게 얼마나 빨라졌는지 궁금해서.. 한번 확인해봤다.
(CPU ONLY 계산 버전, GPU 버전을 만들어서 신경망 정방향 통과 & CROWN
알고리즘(backward) 계산 시간을 측정)

CPU 버전

```
=====
Starting CROWN Verification (eps = 1e-06)
** MODE: CPU ONLY (no GPU) **
=====
calc success
Elapsed time: 101.237800 ms

Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

(101ms)

GPU 버전

```
=====
Starting CROWN Verification (eps = 1e-06)
=====
clear lirpa_forward!

calc success
Elapsed time: 353.057200 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

(353ms)

=====

일단 AI에게 시켜서 대충 최적화한 버전 `my_lirpa_op_only_GPU`,
`crown_test_op_only_GPU.cu`를 만들고 실행해봄

- 여기서 컴파일 옵션에 `-lcublas` 를 넣었는데

-l은 라이브러리를 링크하라는 컴파일러 옵션이고, `cublas`는 NVIDIA가 제공하는 `cuBLAS` 라이브러리입니다. `my_lirpa_op.cu`에서 `cublasDgemm()` (GPU 최적화 행렬곱) 함수를 사용하기 때문에 이 라이브러리를 연결해줘야 합니다. CUDA Toolkit 설치 시 자동으로 포함되어 있어서 별도 설치의 필요 없습니다.

```
=====
Starting CROWN Verification (eps = 1e-06)
** MODE: GPU OPTIMIZED (cuBLAS + Pool) **
=====
calc success
Elapsed time: 229.691800 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
C:\Users\User\Desktop\cuda\crown>
```

적용된 최적화

1. `cuBLAS`로 `matmul` 대체
2. 메모리 풀 사용 (미리 큰 공간을 할당해서 빌려주는 형식으로 함, 대신 함수 호출마다 메모리 할당, 해제를 없앴)
3. 벡터 연산을 `CPU`로 바꿈

229.691ms로 100ms정도 줄었지만 여전히 `CPU`보다 느림

⇒ matmul(행렬곱)만 GPU로 실행하는 하이브리드 프로그램을 만들어봄

```
=====
Starting CROWN Verification (eps = 1e-06)
** MODE: HYBRID (matmul=GPU, rest=CPU) **
=====
calc success
Elapsed time: 201.670100 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

201.670ms , 조금 줄었다. , 여전히 cpu보다 느림

v2에서 적용 방안

1. cuBLAS 미리 예열 : 계산 (시간측정) 전에 미리 cuBLAS 호출해서 초기화 (즉 예열) ← 방법 더미 matmul을 한번 호출 (matmul 안에 cuBLAS가 들어있으니까)
 - a. cuBLAS : 엔비디아(NVIDIA) 그래픽 카드(GPU)에서 빠르게 선형대수 연산을 수행하도록 만든 [NVIDIA Developer](#) 가속 라이브러리
2. 가중치 (W) GPU에 사전 업로드 : 가중치는 고정이므로 네트워크 로드할때 미리 업로드 해놓기 (그리고 matmul에서 호출마다 복사하는 과정 삭제) (memcpy)
3. 16 x 491 행렬같은 부분도 있으니까 이때도 전부 복사하기(현재 기준 512 x 512 , 2MB행렬을 Malloc 하는중)보다 필요한 부분만 복사하기

```

=====
Starting CROWN Verification (eps = 1e-06)
** MODE: HYBRID V2 **
=====
calc success
Elapsed time: 85.785300 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====

```

85ms 드디어 **cpu**보다 빨라짐

미적용 방안

4. 희소행렬의 계산에서는 **cuBLAS** 보다 **cuSPARSE**가 더 효과적 (0인 부분을 건너뛰고 계산) 대체가능 (다만 **CSR**이라는 특수한 행렬을 계산에 이용하므로 변환에 따른 오버헤드가 더 클 수 있음) ← 적용해볼만 함 (해봤는데 **cuBlas**가 더 빠름 // **crown_test_op_hybrid_v2_Sparse**)
5. **memcpy**를 아예 제거하고 **GPU**내에서만 끝까지 돌아가도록 코드 짜기 ← 이건 코드를 갈아엎어야 하므로 보류 (커널 퓨전?)
6. **CUDA stream** 방안 : **Memcpy**와 커널 실행을 겹쳐서 실행 가능하다고 함 ← 이건 아직 모르니까 보류 (멀티 스레딩같은 건가?)

=====

4주차 랩미팅 후 해야할 것 정리

1. CROWN 알고리즘에서 출력한 16개의 값 ⇒
 - a. 신경망을 기준으로 **sorting** (아마 최댓값을 따라가는 듯?) : 최댓값부터 8개의 출력노드를 선택
 - b. **lower_bound, upper_bound** 를 기준으로 **sorting** (아마 간격을 기준으로 따라감) : 8개의 출력노드를 선택하도록 하기

⇒ 이거에 대한 답지는 교수님께서 제공해주시기로 했음

2. 타일링 : 메모리 사이즈에 대해 전부 처리하기 어려우니 일부만 올려서 계산하고 다시 다음부분 올려서 계산하고 하는것은 어떻게 처리하고 있나?
ex) 예를 들어 1~100까지 있다하면 1~10을 올려서 계산하는동안, 11~20을 올리고 그런거..

그래서 지금 혹시 신경망이 매우 커서 GPU램에 다 안올라가는 상황인가? 그렇다면 지금 어떻게 처리를 하고 있나? 를 여쭙보신듯.

2-1. **forward + backward** 로 하고 있으면 , 알고리즘을 봤을때 (신경망과 상관없이) 고정값인 가중치, 편향 행렬이 있다 (적어도 그런 행렬과 벡터가 3쌍 있을것임)
⇒ 즉 신경망 모델 사이즈의 3배정도 메모리를 차지하고 있을것임 (그래서 스택 메모리가 128MB 필요했나?)

그래서 이걸 한번 봐라 (알고리즘을)

3. 그리고 내가 할 것은 성능이 개선된 프로그램을 가져가기 (cpu보다 빠르도록) ← 지금까지 테스트한 것들 가져가면 될듯 + 더 찾아보기

3-1. 메모리 풀(할당, 해제 제거) + **memcpy** 비용 제거한 버전 (고정된 W, B 값)

3-2. **cuBlas , cuSparse**

=====

정리

v0 : 단독 CPU 처리 , **96ms**

v1 : 모든 병렬처리 함수를 커널 함수로 바꿈 , **355ms** // 이게 my_lirpa.cu

v2 : 벡터 연산은 다시 CPU로 처리, 메모리풀, cuBlas 도입 , **229ms** //
crown_test_op_only_GPU.cu

v3 : CPU, GPU 하이브리드(어떤 함수인지는 아래 이미지), 풀 구조체 축소, **200ms** //
crown_test_op_hybrid.cu

이제 `only_GPU` 와 `hybrid` 를 정확하게 비교해 드리겠습니다.

`only_GPU` → `hybrid` 변경점

`only_GPU` 에서 GPU로 돌리고 있던 것들 중, `hybrid` 에서 CPU로 되돌린 함수들:

함수	only_GPU	hybrid	복잡도
<code>make_zero_matrix</code>	GPU (<code>cudaMemset</code>)	CPU (그냥 생성자 초기화)	-
<code>make_zero_vector</code>	GPU (<code>cudaMemset</code>)	CPU (그냥 생성자 초기화)	-
<code>make_eye</code>	GPU 커널	CPU <code>for</code> 문	$O(n)$
<code>mat_add</code>	GPU 커널 + 메모리 풀	CPU <code>for</code> 문	$O(n^2)$
<code>positive_part</code>	GPU 커널 + 메모리 풀	CPU <code>for</code> 문	$O(n^2)$
<code>negative_part</code>	GPU 커널 + 메모리 풀	CPU <code>for</code> 문	$O(n^2)$
<code>rowwise_scale</code>	GPU 커널 + 메모리 풀	CPU <code>for</code> 문	$O(n^2)$
<code>affine_min</code>	GPU 커널	CPU <code>for</code> 문	$O(n^2)$
<code>affine_max</code>	GPU 커널	CPU <code>for</code> 문	$O(n^2)$
<code>matmul</code>	cuBLAS + 메모리풀	cuBLAS + 메모리풀 (동일)	$O(n^3)$

그리고 GPU 풀 구조체도 축소되었습니다:

- **only_GPU:** `d_mat[4]` + `d_vec[2]` (행렬 4개, 벡터 2개 미리 할당)
- **hybrid:** `d_A`, `d_B`, `d_C` 딱 3개만 (matmul 전용)

한 줄 요약

`hybrid` 는 `only_GPU` 에서 **matmul(cuBLAS)**만 남기고 나머지 GPU 커널을 전부 **CPU `for` 문**으로 되돌린 버전입니다. 새로 "추가"된 것은 없고, 오히려 GPU 코드를 ****삭제(CPU로 회귀)****해서 빨라진 케이스입니다.

v4 :

1. cuBLAS 미리 예열 : 계산 (시간측정) 전에 미리 cuBLAS 호출해서 초기화 (즉 예열) ← 방법 더미 matmul을 한번 호출 (matmul 안에 cuBLAS가 들어있으니까)

- cuBLAS : 엔비디아(NVIDIA) 그래픽 카드(GPU)에서 빠르게 선형대수 연산을 수행하도록 만든 [NVIDIA Developer](#) 가속 라이브러리

2. 가중치 (W) GPU에 사전 업로드 : 가중치는 고정이므로 네트워크 로드할때 미리 업로드 해놓기 (그리고 matmul에서 호출마다 복사하는 과정 삭제) (memcpy)

3. 16 x 491 행렬같은 부분도 있으니까 이때도 전부 복사하기(현재 기준 512 x 512 , 2MB행렬을 Malloc 하는중)보다 필요한 부분만 복사하기

85ms

// crown_test_op_hybrid_v2

=====

v1-1 : 벡터연산 중 3가지 (vec_add, sub, mat) 을 cpu로 돌려놓음, **300ms** //

my_lirpa_vector_CPU

(v1-1은 잘못 생각한게 아직 메모리 풀도 안해놔고, cuBlas 같은 것도 안해놔서 cpu로 함수를 돌려놓다 보면 결국 v0의 결과와 같아짐, 그러면 정확한 비교를 할 수 없으니까.. 적어도 gpu를 내가 할 수 있는 범위에서 초기화 해놓고 cpu로 바꾸며 비교 해야할듯)

=====

v1-1-1 : 일단 메모리풀만 도입한 프로그램 만들어봄 , 결과 **205 ~ 250ms** //

my_lirpa_mempool.cu

메모리 풀 크기 산정 근거

풀 크기 산정 근거:

- Matrix 3개: `mat_add` , `matmul` 등에서 최대 3개(A, B, C) 동시 사용
- Vector 6개: `relu_relax` 에서 6개(lower, upper, alpha_l, beta_l, alpha_u, beta_u) 동시 사용

```

=====
Starting CROWN Verification (eps = 1e-06)
=====
clear lirpa_forward!

calc success
Elapsed time: 228.585200 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====

```

v1-1-2 : 가중치만 미리 업로드 할 수 있게 해봄, 어떻게 바꿨냐면, (149~155ms)

// my_lirpa_mempool_preload_on_gpu.cu

```

struct FullyConnectedNetwork {
    int num_layers = 0;
    int layer_in_dim[MAX_LAYERS]{};
    int layer_out_dim[MAX_LAYERS]{};
    Matrix W[MAX_LAYERS]{};
    Vector b[MAX_LAYERS]{};
    ActivationType act[MAX_LAYERS]{};
    double* d_W[MAX_LAYERS]{}; // GPU 사전 로드된 가중치 포인터
};

```

GPU의 메모리 주소를 저장할 수 있는 포인터 배열을 미리 신경망에 만들어놓고

// 이때 포인터 배열의 크기는 MAX_LAYERS를 기준으로 하므로 공간보다 신경망이 작으면 낭비될듯..

- 그리고 double 보다 float가 접근 속도가 더 빠르다는데 행렬, 벡터 구조체 등이 전부 double을 기준으로 하므로 float 포인터를 쓰기 위해서는 전체적으로 갈아엎을 필요가 있다.

```
// 가중치를 GPU에 사전 로드
void pre_upload_weights_to_gpu(FullyConnectedNetwork* net) {
    for (int i = 0; i < net->num_layers; ++i) {
        cudaMalloc(&net->d_W[i], MAX_DIM * MAX_DIM * sizeof(double));
        cudaMemcpy2D(net->d_W[i], MAX_DIM * sizeof(double),
                    net->W[i].a, MAX_DIM * sizeof(double),
                    net->W[i].cols * sizeof(double), net->W[i].rows,
                    cudaMemcpyHostToDevice);
    }
}
```

GPU에서 할당된 메모리를 `net -> d_W[i]` 에 저장 (저장된 메모리를 갖다 쓸 수 있어야 하니까)

```
network read success
data read start: test_data_1.bin
data read success (dim=256)

=====
Starting CROWN Verification (eps = 1e-06)
** MODE: MEMPOOL + Weights PRELOAD ON GPU **
=====
clear lirpa_forward!

calc success
Elapsed time: 149.820400 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563

=====
C:\Users\user\Desktop\cuda\crown>
```

결과 : 149~155ms

- + bias까지 미리 업로드 해봤는데 크게 성능개선에 의미를 미치지 못하는듯 (왜냐하면 이게 bias는 Vector인데 코드를 봤을 때 4KB정도 밖에 안돼서 그렇다, 즉 cpu가

연산하기에도 크게 무리가 없는 수준이라서..) //
crown_test_mempool_preload_on_gpu_plus_bias.cu
잠깐.. 근데 내가 저걸 미리 로드해놓고 정작 matmul 함수에서 활용을 안했는데 어떻게 시간이 줄어든거지..

아.. preload를 하면서 GPU가 워업 되는 것이 원인이었다..

(mempool 버전은 GPU 메모리풀 할당까지 시간에 계산됨, mempool_preload 버전은 가중치를 시간 측정 전에 미리 로드해서 해당 시간이 제외됨)

50ms가 줄어든 진짜 이유: CUDA 컨텍스트 초기화 워업 효과

pre_upload_weights_to_gpu가 t_start 앞에서 cudaMalloc과 cudaMemcpy를 호출하면, 이 시점에 CUDA 드라이버가 처음 깨어나면서:

1. GPU 컨텍스트 초기화 (CUDA 드라이버 로드)
2. GPU 클럭 부스팅 (저전력 → 최대 성능 주파수로 전환)
3. JIT 컴파일 (커널 코드 첫 번째 컴파일)

이 세 가지 초기화 비용이 전부 타이머 구간 밖으로 빠져나가게 됩니다.

반면 mempool 버전에서는

ensure_pool() → 첫 번째 cudaMalloc이 t_start 안에 들어있어서, 저 초기화 비용이 전부 측정에 포함됩니다.

```
mempool 버전:   [초기화 50ms] + [실제 연산] = 측정됨  
preload 버전:   [초기화 50ms] + [실제 연산] = 초기화는 타이머 밖!
```

즉, d_w를 활용해서 빨라진 게 아니라, pre_upload_weights_to_gpu가 의도치 않게 GPU 워업 역할을 하면서 초기화 비용을 타이머 밖으로 밀어낸 것입니다. first_try에서 warmup_cublas()를 명시적으로 두었던 것도 이 이유 때문이었습니다.

즉.. 그냥 v1-1-2는 GPU warmup때문에 50ms가 줄어든 것. (preload 때문 아님)

v1-1-3 : crown_test_preload_fix , 미리 로드한 W 가중치를 제대로 활용하도록 고침

변경점

신경망에 GPU 주소를 저장하던 double * 타입을 Matrix * 타입으로 고침

(이하는 실제로 주소를 활용하도록 바꾼 함수들)

변경 위치	내용	절약 효과/레이어
d_W 타입	double* → Matrix*	커널에 바로 전달 가능
positive_part(W, d_W)	W 복사 스킵	2MB 절약
negative_part(W, d_W)	W 복사 스킵	2MB 절약
matmul(A, W, d_W)	B행렬 복사 스킵 (backward)	2MB × 2회 = 4MB 절약
matvec(W, x, d_W)	A행렬 복사 스킵 (forward)	2MB 절약

그리고 pre_upload_weights_to_gpu 도 memcpy2D 사용이 아니라 Matrix를 할당, 복사하도록 바꿈

근데 my_lirpa_mempool_preload_on_gpu.cu와 비교해 성능 차이가 없어서 100번씩 돌려서 누적시간을 봐보기로 했다..

.. 여기도 별로 성능 차이 안남

500 회 정도 하니까 5~10ms 정도 우세함..

결국 가중치를 미리 로드해서 **memcpy**를 줄이겠다는 건.. 크게 의미를 못미친다.

다시 my_lirpa_mempool.cu로 롤백(v1-1-1)

v1-1-1-1 : 메모리풀에 cuBlas 도입 및 matvec, matmul을 기존 나의 계산이 아닌 cuBlas를 활용하도록 함 //my_lirpa_mempool_cuBlas.cu

```

=====
Starting CROWN Verification (eps = 1e-06)
=====
calc success 500iterations
Total Elapsed time: 61796.584100 ms
Average time per iter: 123.593168 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
계속하려면 아무 키나 누르십시오 . . .

```

(my_lirpa_mempool_cuBlas.cu)
 기존 **v1-1-1** 대비 평균 실행당 시간이 **30ms** 차이난다.

```

=====
Starting CROWN Verification (eps = 1e-06)
=====
calc success 500iterations
Total Elapsed time: 78755.716600 ms
Average time per iter: 157.511433 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
계속하려면 아무 키나 누르십시오 . . .

```

(my_lirpa_mempool.cu 500번) (평균 157ms)

- + 아직 메모리풀 warm up을 안 한 상태임, 이걸 한 뒤에 진행해보자

해봤는데 별로 차이가 안난다.. warm up 한거랑 안한거랑..

오히려 my_lirpa_mempool (cuBlas 없는 버전)이 위에서는 늦게 나온건지 잘나올때는 500회당 평균 120ms 대로 나올 때도 있음...

뭐지.. ← 아마 처음 메모리 풀 할당 비용이 500번의 시행에 묻혀서 크게 차이가 안나는 걸지도

그리고 hybrid_v2 (v4)를 500번 돌리니까 cpu보다 실행 속도가 느려졌다

```
=====
Starting CROWN Verification (eps = 1e-06)
** MODE: CPU ONLY (no GPU) **
=====
Calc success 500iterations
Total Elapsed time: 39148.493900 ms
Average time per iter: 78.296988 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
C:\Users\user\Desktop\cuda\crown\original>
```

```

=====
Starting CROWN Verification (eps = 1e-06)
** MODE: HYBRID V2 **
=====
calc success 500iterations
Total Elapsed time: 49416.462000 ms
Average time per iter: 98.832924 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====

```

이건.. 왜까

⇒ 아마 **cpu**의 캐시 때문이라는 말이 있는 것 같다. // 일단 1번만 돌리는 걸로 실험해야 할듯..

=====

이제 보니 **cuBlas**도 그렇게 영향을 미치진 못하는 것 같다.

그냥 **mempool (v1-1-1)**에서 미리 **ensure_pool()**을 활용해 메모리 할당을 하는 것은 큰 영향을 미치는데 문제는 **cuBlas**를 쓰고 **warm up** 하는 것과 그렇게 차이 나지 않음...

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
```

```
calc success
```

```
Elapsed time: 152.902900 ms
```

```
Output Dimension: 16
```

```
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
```

```
-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

```
계속하려면 아무 키나 누르십시오 . . .
```

```
=====
Starting CROWN Verification (eps = 1e-06), mempool + cuBlas + warmup
=====
```

```
calc success
```

```
Elapsed time: 174.978400 ms
```

```
Output Dimension: 16
```

```
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
```

```
-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

```
계속하려면 아무 키나 누르십시오 . . .
```

이제 보니까 오히려 1번의 시도에서는 cuBlas가 더 느린 모습...

(근데 미리 메모리풀을 warm up 하는 것은 확실히 효과가 있다 각 버전에서 50ms 정도 단축됨)

my_lirpa_optimizing.cu

그럼 여기까지 확실한건 메모리 풀 + warm up 조합은 일단 매우 좋다는 것 (두 개만으로 거의 200ms 단축함) // my_lirpa_mempool_warmup.cu

50ms만 더 단축하면 cpu 따라 잡을 수 있는데.. 흠..

지금 제일 중요한 건 memcpy 병목인데.. 이걸 잡아야 cpu보다 빨라질 수 있음

my_lirpa_mempool_warmup.cu의

make_zero_matrix, make_zero_vector

를 다시 cpu 실행으로 회귀 // 그리고 수식어를 이제부터 optimizing으로 변경

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 128.894800 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
계속하려면 아무 키나 누르십시오 . . .
```

22 ~ 25ms 정도 줄었다!! 이것만으로도 ...

혹시 몰라서 영벡터 만들기는 다시 gpu로 해봤는데 이것도 유의미하게 (3~5 ms) 시간이 늘어남,, 그냥 cpu로 두는게 좋을듯

결과를 담은 벡터를 memcpy 하는 짓 멈추기

(쓸때없이 결과가 저장될 행렬, 벡터도 memcpy 하는 일이 있었는데 이걸 제거하니 10ms 정도 또 줄었음)

```
..
data read start: test_data_1.bin
data read success (dim=256)
Pi
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 115.469900 ms
Output Dimension: 16
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
계속하려면 아무 키나 누르십시오 . . .
```

가중치 , positive_part / negative_part 거친 가중치 GPU 메모리에 미리 올려놓기

(matmul 이나 matvec 에서 memcpy 절반됨 / 양수, 음수부 가중치는 forward 돌때마다 계산 필요없어짐)

```

=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 103.741500 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====

```

(결과 103ms 정도로 이제 거의 cpu와 비슷해졌다)

이제 forward 함수에서 DTOH하는 memcpy를 극단적으로 없앴다.

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 64.716000 ms
Output Dimension: 16


[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
```

64ms ... 엄청 줄었다..

=====

5주차 세미나 이후 해야할 것

1. CROWN 알고리즘의 범위를 잘못 규정하고 있었다.., 즉 접근법이 틀림/ 이걸 **partial order, total order?** 이걸 좀 찾아봐야 할 듯 ← 당장 중요한 건 아는데 음.. 그래도 미리 바꾸면 좋긴 해
2. **Lirpa_Backward_only** 는 지금 **recursive** 한 버전으로 GPU에는 맞지않음 (재귀 실행이라.. 병렬 처리가 안될듯) ⇒ 일단 **lirpa_backward_bound**만 완성한 뒤 테스트 해라 (완성되면 알려줌)
3. 또 나왔음.. 지금 CPU에서 GPU로 메모리 복사를 어떻게 하고 있냐 (신경망 복사를 어떻게 하고 있냐.. 신경망이 매우 큰데 이거 어떻게 나눠서 복사하고 있냐고? 여쭙보심) ⇒ GPU 메모리 사용량을 확실히 알아내는 법은 **Nsight System**



이렇게 올리면 뜬다. 근데 **310MiB**? 이거 뭔가 이상하다.

Gemini가 계산한 건 **114MB** 정도였는데 (메모리 풀에 올라간 행렬, 벡터를 기준으로 계산해봄..)

근데 **CUDA**가 실행(**CUDA API** 의 첫 호출시)되면 **CUDA Context**라는게 생성됨 이게 커널 실행용 기본 메모리, 페이지 테이블, 명령어 큐 등을 관리하는데 이게 **VRAM**을 사용함 + 런타임 오버헤드까지 하면 충분히 프로파일러에 나오는 **VRAM** 사용량은 내가 코드로 계산한 값보다 작을 수 있다.

근데 그거 감안하면 결국 **300MB** 내라는 건데.. 그럼 **VRAM**한테는 그렇게 큰 값은 아니지 않나?

⇒ 이거 발표에 가져가자

4. 차후 계획 3번.. 이 부분 내가 설명을 제대로 못한 것 같아서 다음 발표에 설명을 같이 가져가자

⇒ **sm** , **tile**, **tiling** , **Nsight compute** 등

5. 발표는 항상 탑다운 방식으로 먼저 개괄적인 설명을 하고 내부 내용을 설명하던가 해야지 그냥 **40ms** 줄었다고 막 말하지 말고 (슬라이드를 내가 너무 안읽어 , 나도 읽으면서 설명할 수 있게 만들자 , 대본만 짜지말고)

=====

딱 정해짐 , 이번주 발표내용

1. CROWN 범위 다시 찾아보기 , 인터벌? ...
2. **lirpa_backward_bound** 최적화, **cuBlas**, **cuSparse** 도입
3. 다음 계획 설명하기 (CPU에서 GPU 병목을 잡은 뒤, **global memory**와 **sm**의 병목, **Nsight compute**, **shared memory**, **tile**, **tiling** 등)
4. 그리고 GPU VRAM에 얼마나 올라와있는지 보여주기 (**VRAM** 사용량은 코드로 계산 + **system** 프로파일)

일단 한 일

교수님께 `lirpa_backward_only_iteration_array.cpp` 받음
결과가 잘 나오는지 (이전 CROWN과 동일한지) 테스트

`/testing(present)/crown_test_cpu_iteration.cpp`를 컴파일한 `.exe` 파일들
근데 이 과정에서 스택 메모리가 기존 128MB 로 안되어서 2GB로 늘리니까 됨

```
=====
Starting CROWN Verification (eps = 1e-06)
** MODE: CPU ONLY iteration ver **
=====

calc success
Elapsed time: 193.665600 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

실행결과는 193ms (CPU 버전) , 기존 backward보다 93ms 정도 느림

그 다음에 `backward_only`의 구조체를 도입해야 했는데
`lirpa_backward_only_iteration_array` 의 구조가 `lirpa_forward_backward_fc_array`와 좀 다름
(새로운 함수 추가, 기본 자료구조 등)

그래서 고민해본 결과

1. `backward` 는 그대로 구현 (기존 `lirpa_backward_bound`)
2. 아예 새로운 구조체를 추가 (`backward_only_iteration`, 기존 재귀를 활용한 `backward_only`는 남겨놓음)

현재 `backward GPU` 파이프라인 완성
실행 결과

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
```

```
calc success
```

```
Elapsed time: 26.529100 ms
```

```
Output Dimension: 16
```

```
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
```

```
-----
```

[0]	0.081772	0.082159	0.081966
[1]	0.273538	0.273823	0.273680
[2]	0.102147	0.102482	0.102314
[3]	0.114244	0.114541	0.114393
[4]	2.670552	2.670843	2.670697
[5]	1.846574	1.846872	1.846723
[6]	-1.714750	-1.714490	-1.714620
[7]	-1.880139	-1.879695	-1.879916
[8]	0.706986	0.707275	0.707131
[9]	-2.612086	-2.611722	-2.611904
[10]	0.003713	0.003976	0.003845
[11]	1.310476	1.310817	1.310646
[12]	2.049539	2.049839	2.049689
[13]	-1.025923	-1.025597	-1.025760
[14]	1.082576	1.082852	1.082714
[15]	-3.404772	-3.404355	-3.404563

```
=====
```

26ms

확실히 빠름

근데 실시간성을 확인하려면 마이크로초 ~ 수 밀리초(ms) 내로 제한해야 함

=====

동기화 (cudaDeviceSynchronize) 제거

필요한 부분을 제외하고 동기화 코드 제거함

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 25.457200 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
```

1ms 정도 줄었다

=====

cuBlas 도입함.. 근데 오히려 결과가 안 좋음

- 참고 cuSparse나, cuBlas를 사용할 때는 -lcublas, -lcusparse를 컴파일 옵션에 붙여야 함

그 이유로는

1. 표준 라이브러리(libc)가 아니기 때문임, 표준 라이브러리에 속하는 헤더들(iostream 등)은 include 하면 자동으로 링크됨
2. 표준 라이브러리가 아닌 커스텀 모듈(내가 직접 만들었다던가..) 들도 -l 를 안붙이는데, 그 이유는 코드를 직접 가져와서 통째로 컴파일하기 때문 (즉 구현체가 컴파일에 통째로 들어감)
3. cuBlas, cuSparse 같은 라이브러리들은 Nvidia에서 만든 매우 거대한 소스코드 덩어리라 미리 컴파일 되어있음 (컴파일 하는데 실제로 매우 오래걸림)
4. 소스코드가 없기 때문에 해당 라이브러리를 넣고 한번에 컴파일 불가

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
```

```
calc success
```

```
Elapsed time: 40.050500 ms
```

```
Output Dimension: 16
```

```
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
```

```
-----
```

[0]	0.903952	0.904427	0.081966
[1]	0.990928	0.991328	0.273680
[2]	-0.591686	-0.591280	0.102314
[3]	0.324877	0.325260	0.114393
[4]	2.829982	2.830317	2.670697
[5]	2.199842	2.200121	1.846723
[6]	-2.379492	-2.379074	-1.714620
[7]	-1.422470	-1.421962	-1.879916
[8]	0.788409	0.788821	0.707131
[9]	-2.194350	-2.193915	-2.611904
[10]	1.078205	1.078522	0.003845
[11]	3.603885	3.604276	1.310646
[12]	3.004923	3.005297	2.049689
[13]	-1.185600	-1.185184	-1.025760
[14]	1.494055	1.494391	1.082714
[15]	-3.060963	-3.060550	-3.404563

```
=====
```

40ms 정도로 다시 시간이 늘어남

```
=====
```

혹시 cuSparse는 잘 되나 하고 도입해봤다

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 27.107400 ms
Output Dimension: 16
[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

현재 적용된 범위는 다음과 같습니다.

- `W`, `W_pos`, `W_neg` 를 네트워크 준비 단계에서 CSR 형식으로 변환
- cuSPARSE handle 및 CSR descriptor 유지
- `network_forward()` 의 dense `matvec` 를 cuSPARSE `SpMV` 로 교체
- 기존 `matmul` 은 아직 유지

이렇게 했는데

즉

cuSparse를 이용해서 벡터 곱(spMV)만 적용 해본 상황, 여기서 빠르면 spMM(Sparse 행렬곱) 을 도입하기로 했다.

결과는 27ms .. 좀 더 느려졌다.

해봤는데 27ms 정도 나오네.. 4단계까지 했을때 최소 24ms까지 나왔는데 말이지.. 이러면 계속 진행해야하나? 근데 왜 이러지? cuSparse는 Nvidia에서 직접 최적화한 희소행렬 곱셈을 지원하는 거 아니었나

오후 8:14  

지금은 cuSPARSE를 계속 확장하지 않는 편이 좋습니다. 24 ms baseline으로 돌아가고, cuSPARSE는 별도 실험으로 두세요.

느려진 이유는 cuSPARSE가 최적화되지 않아서가 아니라 현재 workload가 cuSPARSE에 불리하기 때문입니다.

- 행렬 크기가 작고 layer가 3개뿐임
- `SpMV` 호출 횟수가 적어 kernel/descriptor 생성 비용이 큼
- 매 호출마다 `cusparseDnVec` 생성·삭제와 buffer size 계산을 함
- `network_forward()` 가 여전히 layer마다 D2H → CPU `vec_add` → H2D를 수행함
- cuSPARSE는 대규모 sparse throughput에는 강하지만, 작은 연산의 latency에는 custom kernel이 더 빠를 수 있음

특히 현재는 cuSPARSE가 적용된 부분이 `network_forward()` 의 `w*x` 뿐이라 전체 24 ms 중 일부만 영향을 받는데, 그 일부에 오버헤드가 추가된 상황입니다.

나중에 다시 시도한다면 descriptor와 buffer를 미리 만들어 재사용하고, `network_forward()` 전체를 GPU 상주로 만든 뒤 `SpMV` 를 평가해야 합니다. 지금은 24 ms 버전을 기준으로 유지하는 것이 합리적입니다.

혹시 몰라서 `spMM`까지 도입한 후에 결과를 봤다

```
calc success
Elapsed time: 38.580600 ms
Output Dimension: 16
```

[Index]	Lower Bound	Upper Bound	Normal Pred (y)
[0]	1.232060	1.232429	0.081966
[1]	1.339939	1.340349	0.273680
[2]	0.431007	0.431408	0.102314
[3]	3.121480	3.121885	0.114393
[4]	2.898119	2.898479	2.670697
[5]	3.541973	3.542253	1.846723
[6]	-0.424204	-0.423742	-1.714620
[7]	-0.951575	-0.951086	-1.879916
[8]	3.576376	3.576872	0.707131
[9]	-3.821863	-3.821336	-2.611904
[10]	1.800856	1.801248	0.003845
[11]	3.880063	3.880416	1.310646
[12]	3.075189	3.075570	2.049689
[13]	-0.533501	-0.533005	-1.025760
[14]	2.420017	2.420428	1.082714
[15]	-1.841872	-1.841407	-3.404563

거의 40ms로 회귀.. 이러면 안된다.

음.. 너무 신경망이 작아서 그런걸지도 모른다는 의견이 있다

현재 주 측정에서는 cuSPARSE `SpMV/SpMM` 을 빼고 기존 dense `matvec/matmul` 을 유지하는 것이 맞습니다.

이유는:

- `network_forward()` 는 전체 타이머에 포함되지만, 현재 cuSPARSE pipeline이 완성된 상태가 아님
- `SpMV / SpMM` 호출마다 descriptor와 buffer 처리 비용이 추가됨
- 모델과 layer 수가 작아 실제 sparse 연산보다 setup/launch 비용이 더 큼
- SpMM 적용 후 38 ms가 된 것은 이 오버헤드가 계산 이득보다 큰 상황

따라서 공식 결과는 24 ms dense baseline으로 유지하고, cuSPARSE는 별도 benchmark 옵션으로 비교하는 게 좋습니다.

(그리고 `network_forward`는 신경망의 일반 추론값을 출력하는데 이게 아직 GPU 파이프라인이 아니라서 최적화가 안되어있기도 하고..)

cuBLAS와 **cuSPARSE**는 실험했지만 현재 모델 크기와 호출 패턴에서는 느려졌으므로, 현 기준 코드에는 포함하지 않은 상태, 후에 다시 도입해보는 시도가 필요함

원인 분석

1. 신경망의 크기가 매우 작다.
2. cuBlas, cuSparse 의 동작 방식에서 오버헤드가 생겼다. (이 또한 신경망이 작기 때문에)

아직 실험해볼 여지는 많다. 현재까지는 cuBlas, cuSparse에 있는 기본적인 형태의 행렬곱 연산 함수를 사용했는데, 행렬곱에도 변형 함수들이 매우 많다. ← sm 내의 분석과 함께 사용해야 하는 함수들이라 Nsight compute 분석때 같이 진행하면 될 듯?

=====

그 다음으로는 커널 퓨전을 진행함

먼저 backward_bound_gpu()에만 진행했는데..

23ms 후반대까지는 나오는 듯 ?

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 23.925200 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
```

(컴퓨터 사정에 따라 26까지 뛰는 경우도 있지만.. 중요한건 23ms 정도가 보인다는것)

이후 `lirpa_forward_bound` 에서 사용하는 함수들을 커널 퓨전해서 성능을 개선해봄

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 22.342900 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

22ms 초반까지 나온다.

늦으면 28까지도 나오는데 , 보통은 24 중반정도

=====

그 외에도

1. `backward_bound_gpu`에서 사용하는 `affine` 중복 계산 삭제 (커널 2개 함수 줄어듦)
2. `backward_bound_gpu`에서 사용하는 `new_(upper, lower)_p`를 복사하지 않고 `swap` 함수를 이용해서 포인터 스와핑 (`std::swap` 이용)
3. `backward` 에서 사용하는 행렬곱 커널 2개를 하나로 합친 커널 함수 만듦 ,
`backward_matmul_pair_gpu` ⇒ 22ms 보이는 비율이 늘었다.. 최저점(28ms)도 잘 안보이게 됐고 체감상, 효과가 있는듯
4. `build_coeff_pair_fused_gpu` 커널 퓨전
5. `backward_bias_pair_fused_gpu` 커널 퓨전

```

=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 22.157400 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====

```

5번까지 적용하고 최고 성능 나왔는데..

계속 해서 1개의 커널 호출로 줄일 수 있는 커널 함수에 대해 커널 퓨전 모두 진행함

커널 퓨전 + `set_shape` 함수를 다른 커널함수들에 직접 내장한 결과

```
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 21.375300 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
=====
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

최저 21ms 까지 가능하다!!

=====

forward - backward 간에 전달되는 alpha, beta 값을 메모리 풀에 올려서 전달 과정 삭제함
변경 내용:

- 레이어별 alpha/beta GPU 버퍼를 메모리 풀에 추가
- forward에서 alpha/beta를 GPU에 레이어별로 저장
- backward가 host `ForwardBoundResult` 에서 alpha/beta를 H2D 복사하지 않고 GPU 버퍼를 직접 사용
- alpha/beta 저장용 D2D 복사 4회를 `cache_relaxation_layer_gpu` 1회로 통합

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 21.018800 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | Normal Pred (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
```

21.0ms 정도 나온다

=====
bias 도 메모리 풀에서 관리 하도록 함
성능의 최고점이 오르지 는 모르겠는데 ,
21 ~ 23ms 내에서 (특히 21 ms) 꽤 안정적으로 동작함

NVTX 구간 내에서 memcpy 가 109 ⇒ 94 번 호출, 15번 감소

=====
backward 호출시 forward를 호출하는데, forward의 중간 결과를 CPU (메모리)에
복사(memcpy)하는 여부의 플래그를 도입

(false로 할 경우 memcpy 가 현저히 줄어듦)

```
=====  
Starting CROWN Verification (eps = 1e-06) mempool + warmup  
=====  
calc success  
Elapsed time: 17.223600 ms  
Output Dimension: 16  
[Index] | Lower Bound | Upper Bound | Normal Pred (y)  
-----  
[ 0] | 0.081772 | 0.082159 | 0.081966  
[ 1] | 0.273538 | 0.273823 | 0.273680  
[ 2] | 0.102147 | 0.102482 | 0.102314  
[ 3] | 0.114244 | 0.114541 | 0.114393  
[ 4] | 2.670552 | 2.670843 | 2.670697  
[ 5] | 1.846574 | 1.846872 | 1.846723  
[ 6] | -1.714750 | -1.714490 | -1.714620  
[ 7] | -1.880139 | -1.879695 | -1.879916  
[ 8] | 0.706986 | 0.707275 | 0.707131  
[ 9] | -2.612086 | -2.611722 | -2.611904  
[10] | 0.003713 | 0.003976 | 0.003845  
[11] | 1.310476 | 1.310817 | 1.310646  
[12] | 2.049539 | 2.049839 | 2.049689  
[13] | -1.025923 | -1.025597 | -1.025760  
[14] | 1.082576 | 1.082852 | 1.082714  
[15] | -3.404772 | -3.404355 | -3.404563  
=====
```

17ms

효과:

- `cudaMemcpy` : 94회 → 54회
- D2H: 44회 → 20회
- CUDA API 복사 시간: 약 7.61ms → 3.51ms
- 실행 시간 1회 측정: 약 20.22ms
- 결과값은 기존과 동일하게 출력됨

=====

6번째 세미나 이후 할 일

1. 대학원 AI 프로그래밍 - 논문... .. 라고 하시던데 영상 다시 보고 확인해야할듯? < 아마 공유된 논문 **git repository**가 있으니 같이 보면 좋을 것 같은데... 라고 하셨나? 영상 보자
 2. ~~6번 세미나 3번 슬라이드에 RAM 추가하자 < 해결~~
 3. 외부 라이브러리 **cuBlas, cuSparse** 일단은 도입하지 말자 (나중에 때 되면 진짜 할거 없으면 하는걸로) < 계속 **gemini**가 넣으면 좋다고 하니까.. **cuBlas**는 진짜 다 하고 테스트 해보는 걸로
 4. **backward_only** 일단 하지마, 그냥 **forward** 만 진행해, ⇒ **forward + backward** 로 계속 진행하고 최적화 하는 것이 더 나을듯? 생각보다 결과가 잘 나오고 있다는 점을 고려해서 (교수님 의견임) // 원래는 **f, b, b_only**가 신경망의 특성때문에 거의 결과가 비슷하다. 그래서 시간이 상대적으로 덜 걸리는 **forward**만 하는 거 어때냐? 였는데 **backward**가 잘 진행되고 있어서 계속 가도 될 듯 하다
 5. CROWN range 정렬 문제에 대한 해답
https://github.com/kwanghoon/NNV/blob/main/localrobustness_fwd_bwd.py
여기 코드가 있으니 보고 이해해서 알고리즘 완성하자
- 출력 결과는 16개의 1 or 0이 출력 (1이면 선택된 인덱스, 0이면 선택안된 인덱스임)
6. 학부 연구생 논문 작성해보자 .. (이건 나중에)
 7. Nsight compute 분석해서 **CUDA core** 점유율이 50%정도만 넘어도 잘된 편이라 생각할 수 있다고 한다 (50% 넘기는 걸 목표로 해보자)

적용할 것은

1번 `network_forward`(추론) 중간 복사 제거

여기서 바꾸는 과정에 주목할 부분

```
// 3. GPU 내부에서 활성화 함수 적용
// 여기서 CPU 메모리에 있는 net.act[1]를 사용했는데, CUDA 커널 인자 방식을 이해해야함
apply_activation_gpu<<<blocksPerGrid, 256>>>>(net.act[1], d_out);
```

커널 함수의 호출에 `net.act[]` 을 사용했는데 애는 메모리풀에 올리고 관리한 적이 없다.
(활성화 함수)

gemini에 따르면

위 코드가 실행될 때, CPU는 `net.act[]`이 가리키는 메모리 주소(Pointer)를 GPU에 넘겨주는 것이 아닙니다. 대신, CPU가 자기 메모리에서 `net.act[]`의 **값(예: Relu면 0, Sigmoid면 1)**을 읽은 다음, 그 숫자 자체를 GPU 커널을 발사할 때 매개변수 주머니(Constant Memory / Registers)에 쏙 넣어서 같이 쏘아 보냅니다.

`ActivationType`은 단순한 enum(내부적으로는 4바이트짜리 정수)이기 때문에:

별도로 `cudaMalloc`이나 `cudaMemcpy`를 할 필요가 전혀 없습니다.

커널을 런칭할 때 값이 자동으로 GPU로 넘어가므로 속도 저하도 없습니다.

반면에 크기가 엄청나게 큰 배열이나 구조체 내부의 데이터는 이렇게 값으로 넘기면 터지기 때문에, 우리가 포인터(*d_out, *g_pool.d_weight)를 써서 `cudaMemcpy`로 올려두고 주소만 넘겨준 것입니다.

즉, 용량이 큰 덩어리는 포인터로 넘기고, 작은 숫자나 열거형(Enum)은 그냥 값으로 쏘줄 수 있다.

좀 더 정확히 설명해보자

저런식으로 쓸 수 도 있다는거? 꼭 GPU 메모리에 올라간것만 인자로 쓰는게 아니고?

네, 맞습니다! 아주 정확한 통찰력입니다. 🧐

CUDA 프로그래밍을 처음 배울 때 "GPU에서 쓸 데이터는 무조건 `cudaMalloc` 으로 할당하고 `cudaMemcpy` 로 올려야 한다"고 흔히 배우지만, 사실 커널의 괄호 (...) 안에 들어가는 매개변수(Argument)들은 그 규칙의 예외입니다. 정확히 정리해 드리면 이렇습니다:

1. 포인터(배열)는 반드시 GPU 메모리여야 한다.

```
cpp
// d_out은 무조건 cudaMalloc된 GPU 메모리 주소여야 함!
apply_activation_gpu<<<...>>>(net.act[1], d_out);
```

배열이나 거대한 행렬은 크기가 너무 크기 때문에, CPU가 커널을 쓸 때 그 데이터를 다 싸들고 던져줄 수가 없습니다. 그래서 사전에 `cudaMemcpy` 로 짐(데이터)을 VRAM에 다 옮겨두고, 커널한테는 ***니가 작업할 짐은 저기 주소 (`d_out`)에 놔놔어***라고 알려주지만 해야 합니다.

2. 스칼라(단일 숫자)는 그냥 CPU 변수를 써도 된다.

```
cpp
// net.act[1]는 그냥 CPU 메모리에 있는 단순 정수(Enum)값!
apply_activation_gpu<<<...>>>(net.act[1], d_out);
```

반면에 `int`, `float`, `double`, `enum` 같은 단일 숫자들은 크기가 4바이트~8바이트밖에 안 됩니다. CPU가 커널 실행 명령(Launch)을 GPU로 쓸 때, 굳이 택배(`cudaMemcpy`)를 부를 필요 없이 실행 명령서 귀퉁이에 포스트잇처럼 값을 딱 붙여서 같이 날려버립니다. (이 공간을 Parameter Bank 또는 Constant Memory라고 부릅니다.)

그래서 우리가 `matvec_bias_gpu<<<blocksPerGrid, 256>>>(...)` 라고 쓸 때, 256 이나 `blocksPerGrid` 같은 CPU 쪽 숫자 변수들을 자유롭게 쓸 수 있는 것도 같은 원리입니다.

정말 핵심적인 CUDA 아키텍처의 동작 원리를 완벽하게 꿰뚫어 보셨네요! 주석 달아두신 내용이 100% 정답입니다.

정리하면 포인터 변수는 `memcpy`를 써서 올려야함 (참조할 크기가 매우 크고.. 결국 CPU가 그 내용을 전부 직접 복사해서 커널 함수의 매개변수 주머니?(일단 주머니라 표현함)에 값을 넣어줄 수 없음,

반면 값만 나오는 경우 (4 ~ 8byte까지는 가능한 듯,) CPU가 직접 그 부분을 참조해서 값을 싸줄 수 있다.

결과는


```

=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 16.914800 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | inference (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====

```

16 초 후반까지 나오게 됨



2 of 56 matches Name ▼ memcpy

Start	Duration	TID	Description:
0.398832s	26.601 μs	14016	Call to cudaMemcpy Memory copies Begins: 0.399947s Ends: 0.40014s (+192.590 μs)
0.398862s	1.084 ms	14016	
0.399947s	192.590 μs	14016	

호출 횟수로 비교하면 memcpy가 66 -> 56개로 줄었다.

=====

backward_bound_gpu에서 기존에는 GPU (backward_bound_gpu 계산결과) -> CPU
 이후
 CPU에서 affine_min/max를 통해 계산을 수행한 후 최종결과를 얻는 방식이었다
 (이 때 affine_min/max 도 GPU에서 계산이 돌아가기 때문에
 GPU -> CPU -> GPU -> CPU 불필요한 복사가 발생됨
)

이 부분에서 affine_min/max까지 backward_bound_gpu에서 실행되도록 개선하여
 GPU -> CPU 이렇게 메모리 복사를 최소화함

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 15.828400 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | inference (y)
-----|-----|-----|-----
[ 0] | 0.081772 | 0.082159 | 0.081966
[ 1] | 0.273538 | 0.273823 | 0.273680
[ 2] | 0.102147 | 0.102482 | 0.102314
[ 3] | 0.114244 | 0.114541 | 0.114393
[ 4] | 2.670552 | 2.670843 | 2.670697
[ 5] | 1.846574 | 1.846872 | 1.846723
[ 6] | -1.714750 | -1.714490 | -1.714620
[ 7] | -1.880139 | -1.879695 | -1.879916
[ 8] | 0.706986 | 0.707275 | 0.707131
[ 9] | -2.612086 | -2.611722 | -2.611904
[10] | 0.003713 | 0.003976 | 0.003845
[11] | 1.310476 | 1.310817 | 1.310646
[12] | 2.049539 | 2.049839 | 2.049689
[13] | -1.025923 | -1.025597 | -1.025760
[14] | 1.082576 | 1.082852 | 1.082714
[15] | -3.404772 | -3.404355 | -3.404563
=====
```

결과는 15ms 후반까지 나옴

해본 결과 추가로 최적화 부분 찾음

```
// 3. GPU 안에서 최종 정답 계산
// 커널 퓨전 가능할듯
affine_min_gpu<<<blocksPerGrid, 256>>>(lower_M, lower_p, d_xl, d_xu, d_final_lower);
affine_max_gpu<<<blocksPerGrid, 256>>>(upper_M, upper_p, d_xl, d_xu, d_final_upper);
```

이부분 커널 퓨전 가능할듯

미리 작성해둔 퓨전 함수가 있어서 사용함

```
// 커널 퓨전 완료 (affine_min과 affine_max를 하나의 커널로 병합)
affine_minmax_pair_gpu<<<blocksPerGrid, 256>>>>(
    lower_M, lower_p, upper_M, upper_p, d_xl, d_xu, d_final_lower, d_final_upper);
```

```
Starting CROWN Verification (eps = 1e-06) mempool + warmup
```

```
=====
calc success
Elapsed time: 15.751000 ms
Output Dimension: 16
```

[Index]	Lower Bound	Upper Bound	inference (y)
[0]	0.081772	0.082159	0.081966
[1]	0.273538	0.273823	0.273680
[2]	0.102147	0.102482	0.102314
[3]	0.114244	0.114541	0.114393
[4]	2.670552	2.670843	2.670697
[5]	1.846574	1.846872	1.846723
[6]	-1.714750	-1.714490	-1.714620
[7]	-1.880139	-1.879695	-1.879916
[8]	0.706986	0.707275	0.707131
[9]	-2.612086	-2.611722	-2.611904
[10]	0.003713	0.003976	0.003845
[11]	1.310476	1.310817	1.310646
[12]	2.049539	2.049839	2.049689
[13]	-1.025923	-1.025597	-1.025760
[14]	1.082576	1.082852	1.082714
[15]	-3.404772	-3.404355	-3.404563

흠.. 0.2ms 정도 하한선이 낮아진 듯?

Backward 메모리 복사 제거 및 초기화 최적화

- Forward 단계의 입력 버퍼($x_0 \pm \text{eps}$)를 Backward에서 재사용하여 H2D 복사 제거
- default 초기 상태(단위행렬/영벡터)를 GPU 커널에서 직접 생성하여 PCIe 통신 오버헤드 최소화

```
=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 13.939000 ms
Output Dimension: 16

[Index] | Lower Bound | Upper Bound | inference (y)
-----|-----|-----|-----
[ 0]    | 0.081772    | 0.082159    | 0.081966
[ 1]    | 0.273538    | 0.273823    | 0.273680
[ 2]    | 0.102147    | 0.102482    | 0.102314
[ 3]    | 0.114244    | 0.114541    | 0.114393
[ 4]    | 2.670552    | 2.670843    | 2.670697
[ 5]    | 1.846574    | 1.846872    | 1.846723
[ 6]    | -1.714750   | -1.714490   | -1.714620
[ 7]    | -1.880139   | -1.879695   | -1.879916
[ 8]    | 0.706986    | 0.707275    | 0.707131
[ 9]    | -2.612086   | -2.611722   | -2.611904
[10]    | 0.003713    | 0.003976    | 0.003845
[11]    | 1.310476    | 1.310817    | 1.310646
[12]    | 2.049539    | 2.049839    | 2.049689
[13]    | -1.025923   | -1.025597   | -1.025760
[14]    | 1.082576    | 1.082852    | 1.082714
[15]    | -3.404772   | -3.404355   | -3.404563
=====
```

.. 13ms 후반 거의 14ms 정도로 봐도 된다.

여기서 fp32 에 단정밀도 연산으로 바꿔보기도 했는데 이 부분은 fp32에 대한 고찰에 있다.

=====

=====

7번째 세미나 이후 할 일 (8/20)

1. 영진아 형아 진행하는 주제를 다음주에 미팅을 잡아서 질문을 해보자
2. 테스트 데이터 1개에 대해 테스트를 진행했으니까 ⇒ 40000개의 전체 데이터에 대해서 진행해봐라 (최적화를 하는것보다는?), (추가 의견. **forward, backward** 2개에 대해서) - 찬희씨랑 컨택이 필요할거다 (40000개에 대해 입력을 주고 출력을 확인하는 코드가 작성되어 있다, 그걸 물어보는게 맞을듯)
3. 안테나 선택 신경망에서 **sparse** 행렬에 대해 했을 때 **dense** 행렬보다 빠르다는 결과를 내기 위해 찬희씨가 테스트를 진행중인데, **dense** 행렬 or **sparse** 행렬을 하나 골라서 같은 조건에서 **cpu**로 순차처리랑 **gpu** 병렬처리를 비교하면 될 듯 (더 빨라진다는 결과 + 어떻게 병렬 개선을 했는지 * 이걸 지금까지 한 내용을 모두 정리하면 된다, 지금까지 포팅작업을 하며 있었던 일을 모두 기록해놔음)
4. **FP32** 로 바꾸었을 때 **Nsight Compute** 해보는 건 재미있을듯 하다 (교수님 의견) - > 캐시 히트율이나 처리량.. + **FP32**를 이용하면 이 과정에서 이론적으로는 **64-32** 바꾸는 과정에 정밀도가 보장되는 방법이 있지만 실제로는 빼앗아서 결과가 40000개중 몇개는 다를수도.. 그 부분은 다시 테스트를 해서 이유를 분석하기

CUDA로 왜 구현 했는가(그걸 나한테 시킨 이유)

1. **CUDA** 프로그래밍 역량을 가진 사람
2. 안테나 신경망 검증 알고리즘을 하드웨어에 구현해서 실시간 검증에 관심있음 -> 하드웨어에 구현을 할 수 있는(실시간 검증) 여지가 있다. 는 논문의 뒷받침 논문으로 작성 가능

CROWN 알고리즘 개발 팀에서도 **GPU**를 활용한 검증 가속을 한적은 있지만 실시간으로 하겠다는 뜻은 아니고 완벽하게 수행하기 위해 모든 경우를 다 따져봐야 한다 그 때 병렬성이 생기고 그걸 빠르게 하겠다. 관점에서 사용한 적 있음

이건 영상 다시 봐야할 듯 ← 레알로 다시 봐야함

생각해보니 교수님이 이런 질문을 하셨다

kernel 시간이 높을수록 좋다고 했는데 그럼 **compute throughput**도 높을수록 좋은게 아니냐?

이 부분에 대해 나는 단순히 **Nsight System**에서는 **cpu - gpu** 간 메모리 교류 비율이 줄어들면 **GPU** 커널 비중이 늘어나니까 **kernel**은 높을수록 좋고, **compute throughput**은 쓸때없이 비효율적인 알고리즘때문에 하드웨어의 한계에 부딪혀서 그럴 수 있다고 생각했다...

근데 그럴네? **Nsight System**의 **kernel**도 단순히 높을수록 좋은게 아니라 왜 높은지까지 분석을 하고 좋다고 판단해야한다.. ← 왜냐? **CPU- GPU**는 안줄어들고 비효율적인 **GPU**의 계산 실행으로 계산 시간이 늘어난다면... 그것 또한 커널 비중의 증가로 이어지니까..

결국 Nsight System의 kernel도 높아지고 메모리 비중이 줄어든다면 내가 제대로 최적화를 했기 때문에 이런 방향으로 나아가는지, 아니면 내가 kernel에서 실행시간이 증가(커널 자체의 최적화가 안되어 증가했는지)했기 때문에 이렇게 된 건지 따져봐야한다.

이부분은 꼭 다음 세미나에 넣자.

먼저 저번 발표내용에 대해서 정정드리겠습니다.

Nsight system의 **kernel** 비중은 커질수록 좋고, **Nsight compute**의 **compute throughput**은 높아지면 이유를 분석해보고 좋은지 판단해야한다라고 말씀드렸는데, 잘못된 부분이 있습니다.

Nsight system의 **kernel** 또한 **CPU-GPU** 사이의 메모리 병목은 그대로인데 **kernel** 실행 시간이 잘못된 커널 작성으로 인해 느려진다면 그것 또한 **kernel**의 비중 증가로 늘어날 수 있습니다. 결국 **kernel**의 비중 또한 **Compute throughput**과 같이 최적화를 제대로 진행했기 때문에 커진 것인지 원인을 따져보고 적절히 판단해야 할 것 같습니다. 메모리 **throughput** 또한 낮아진 이유가 최적화가 잘되었기 때문인지 아니면 메모리 활용을 잘 하지 못하고 있는 것인지 정확히 분석한 이후 판단하는 것이 좋습니다.

forward도 해봤다

```
221     std::cout << "=====\n" << std::endl;
222
223     // 5. 전체 시간 측정 시작
224     auto total_start = std::chrono::high_resolution_clock::now();
225
226     // 6. eps x 데이터 이중 루프 (sparse.py sweep() 와 완전히 동일)
227     for (double eps : eps_list) {
228         int t_count = 0, f_count = 0;
229         float eps_f = static_cast<float>(eps);
230
231         for (int i = 0; i < N; ++i) {
232             // 신경망 정방향 통과
233             Vector y0 = network_forward(*net, dataset[i]);
234             // CROWN backward bound or forward bound 계산
235             // BackwardBoundResult bwd = lirpa_backward_bound(*net, dataset[i], eps_f, false);
236             const ForwardBoundResult bwd =
237                 lirpa_forward_bound_impl(*net, dataset[i], eps_f, true);
238
239             // Top-k 인증 판정
240             if (certify_topk(y0, bwd.final_lower, bwd.final_upper, k))
241                 ++t_count;
242             else
243                 ++f_count;
```

crown_test_optimizing 과 동일하게 실행했는데

40000번의 루프에서는 **backward**보다 **forward**가 느린것을 확인함, 왜일까?

⇒ 원인은 중간 레이어 결과를 저장하느냐/ 마느냐의 플래그에 있었다.

forward_bound_impl의 플래그를 **true**로 두면 중간 결과가 복사됨,

단일 실행에서는 **D2H** 오버헤드가 연산 오버헤드를 뛰어넘지 않았는데

40000번 * 각 **eps** 테스트를 반복하면서 D2H 복사 오버헤드가 **backward** ⇒ **forward** 계산의 이득을 뛰어넘어버린 것임..

그래서 저걸 **false**로 바꾸고 테스트해보자

근데 저 플래그 하나가 **forward**에서는 **layer**의 중간 계산 결과 + 최종 결과까지 D2H 복사를 제어하는 역할을 했던 말임..

⇒ **forward**의 플래그를 3개로 늘림 (중간 결과(**layer_bound** 복사용), **final_affine** 복사용, 최종 결과 복사용)

⇒ 그리고 **backward**의 플래그도 기존의 **layer_bound**와 **backward result**의 **affine_bound**를 같이 복사할지 제어하는 플래그를 각각 2개로 분리했다.

또한 **forward** 최종 계산(result -> lower/upper bounds)을 D2H 복사 하는데에서 비효율적인 부분이 있어서 정확한 테스트를 위해 최적화를 진행함

그래서 일단 **backward**가 **forward**보다 빠른 문제는 해결 (**forward** 최적화 해서)

=====

근데 각각 **forward**, **backward** 결과를 보니 단일 테스트 결과로 비교하면 단순히 다중 데이터셋을 가지고 테스트 했을 때 3배 차이가 나야하는데 왜 그렇게 안나오지?

⇒ **Nsight system** 분석을 이용하기로 했다

일단. 단일 데이터에 대한 **memcpy** 호출 횟수는 각각 **forward/backward** 6번

	Num Calls	Avg	Med	Min	Max	StdDev	Name
s	6	182.834 µs	21.129 µs	9.434 µs	932.351 µs	368.454 µs	cudaMemcpy
s	38	10.788 µs	5.229 µs	3.159 µs	37.064 µs	9.384 µs	cudaLaunchKernel
s	4	16.547 µs	7.845 µs	4.648 µs	45.852 µs	19.644 µs	cudaMemset
s	12	500 ns	362 ns	269 ns	1.509 µs	374 ns	cuLibraryGetKernel
s	38	112 ns	92 ns	73 ns	251 ns	42 ns	cuKernelGetName

나는 여기서

입력 데이터 +- **eps** , 가중치 , **bias** , **upper bound** 결과, **lower bound** 결과 해서 총 6개인줄 알았는데

생각해보니

이미 가중치 , **bias**는 **nvtx** 찍기 전에 한번에 올라가고.. (**prepare network on gpu**)

입력 데이터 +- **eps** 이랑 **upper bound**, **lower bound** 결과 해서 총 4번만 복사해야하는 거 아닌가?

아..

신경망 추론 결과에서

입력값 (**H2D**) , 추론값 (**D2H**)

그리고

CROWN 에서 입력 데이터 +- **eps** 랑 **upper/lower bound** 해서 총 6개

그럼 프로그램 전체 실행에서 18번이니까 6번 빼면 외부에서 12번
가중치 행 (3개 , 신경망 구조가 256 * 491 * 491 * 16 이니까 * 개수만큼)

(가중치 + 가중치 양수부 / 음수부 + bias) * 3

forward - (일단 40000개 의 데이터에 대해서만 테스트 했을 때)

▼	Total Time	Num Calls	Avg	Med	Min	Max	StdDev	Name
79.7%	40.726 s	240000	169.691 µs	18.120 µs	3.599 µs	7.616 ms	316.565 µs	cudaMemcpy
17.0%	8.698 s	1520000	5.722 µs	3.843 µs	2.785 µs	6.908 ms	9.200 µs	cudaLaunchK
3.0%	1.523 s	160000	9.518 µs	5.344 µs	2.696 µs	7.272 ms	20.329 µs	cudaMemset
0.4%	184.318 ms	1520000	121 ns	96 ns	70 ns	196.708 µs	398 ns	cuKernelGetN
0.0%	7.814 µs	12	651 ns	449 ns	242 ns	1.903 µs	545 ns	cuLibraryGetK

CROWN_SWEEP [64.064 s]

backward - (일단 40000개의 데이터에 대해서만 테스트 했을 때)

Total Time	Num Calls	Avg	Med	Min	Max	StdDev	Name
18.527 s	2160000	8.577 µs	7.208 µs	2.779 µs	7.565 ms	14.922 µs	cudaLaunchK
11.332 s	240000	47.216 µs	24.612 µs	3.642 µs	7.404 ms	51.755 µs	cudaMemcpy
2.121 s	160000	13.259 µs	8.447 µs	2.684 µs	2.041 ms	14.919 µs	cudaMemset
392.770 ms	2160000	181 ns	160 ns	74 ns	222.425 µs	713 ns	cuKernelGetN
16.718 µs	18	928 ns	638 ns	304 ns	2.763 µs	767 ns	cuLibraryGetK

CROWN_SWEEP [98.995 s]

cudaMemcpy 횟수는 동일함

forward 전체 실행 시간이 약 64s / backward 전체 실행 시간이 약 98s 정도..

눈에 띄는 점은 동일한 호출 횟수임에도 불구하고 forward의 cudaMemcpy 시간이 월케 많이 잡히냐는 것..

결국 여기서 물어보는 것은

단일 테스트 **forward, backward**는 시간에서 3배 차이가 나는데 , 왜 92만개의 데이터를 돌리면 비슷해지는가? (1분 정도 차이나긴 함..)

⇒ 아직 해결 못함..

=====

```

236
237     const Vector* lb = nullptr;
238     const Vector* ub = nullptr;
239     ForwardBoundResult fwd;
240     BackwardBoundResult bwd;
241
242     // 5. 전체 시간 측정 시작
243     auto total_start = std::chrono::high_resolution_clock::now();
244     nvtxRangePushA("CROWN_SWEEP");
245
246     // 6. eps x 데이터 이중 루프 (sparse.py sweep() 와 완전히 동일)
247     for (double eps : eps_list) {
248         int t_count = 0, f_count = 0;
249         float eps_f = static_cast<float>(eps);
250
251         for (int i = 0; i < N; ++i) {
252             // 신경망 정방향 통과
253             Vector y0 = network_forward(*net, dataset[i]);
254             // CROWN backward bound or forward bound 계산
255             switch(method){
256                 case 0:
257                     fwd = lirpa_forward_bound_impl(*net, dataset[i], eps_f, false, false, true);
258                     lb = &fwd.final_lower;
259                     ub = &fwd.final_upper;
260                     break;
261                 case 1:
262                     bwd = lirpa_backward_bound(*net, dataset[i], eps_f, false, false);
263                     lb = &bwd.final_lower;
264                     ub = &bwd.final_upper;
265                     break;
266                 default:
267                     break;
268             }
269
270             // Top-k 인증 판정
271             if (certify_topk(y0, *lb, *ub, k))
272                 ++t_count;
273             else
274                 ++f_count;
275

```

그리고 중간에 이런 작업을 했다.

간단하게 보면 매번 **forward** , **backward**를 할 때 번거로워서 커맨드라인 실행 인자를 주고
그거에 따라 **forward** 또는 **backward**를 실행하도록 바꿨는데...

```

eps= 9.0e-03: T= 0 F=33333 ratio=0.000
eps= 1.0e-02: T= 0 F=40000 ratio=0.000
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1560.37s
results saved to results_cuda.csv

```

이게 기존 번거롭게 **backward** 할때의 실행 결과고 (1560s)

```

eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 2164.98s
results saved to results_cuda.csv

```

이게 위와 같이 코드를 바꿨을 때 실행 결과다.. (2164s)

거의 600초== 10분 느려졌다..
왜일까..

코덱스 말로는

```
239 ForwardBoundResult fwd;
240 BackwardBoundResult bwd;
241
242 // 5. 전체 시간 측정 시작
243 auto total_start = std::chrono::high_resolution_clock::now();
244 nvtxRangePushA("CROWN_SWEEP");
245
246 // 6. eps x 데이터 이중 루프 (sparse.py sweep() 와 완전히 동일)
247 for (double eps : eps_list) {
248     int t_count = 0, f_count = 0;
249     float eps_f = static_cast<float>(eps);
250
251     for (int i = 0; i < N; ++i) {
252         // 신경망 정방향 통과
253         Vector y0 = network_forward(*net, dataset[i]);
254         // CROWN backward bound or forward bound 계산
255         switch(method){
256             case 0:
257                 fwd = lirpa_forward_bound_impl(*net, dataset[i], eps_f, false, false, true);
258                 lb = &fwd.final_lower;
259                 ub = &fwd.final_upper;
260                 break;
261             case 1:
262                 bwd = lirpa_backward_bound(*net, dataset[i], eps_f, false, false);
263                 lb = &bwd.final_lower;
264                 ub = &bwd.final_upper;
265                 break;
266             default:
267                 break;
268         }
```

문제가 이부분에 있다고 한다.

먼저 **switch**의 스코프 바깥에 **CROWN** 결과를 담을 구조체를 선언해놓고
반복문 내부에서 **CROWN** 을 돌려서 결과를 담고 있는데, 이 부분이 옛날에 배웠듯, 값에
의한 복사란 말이다

그래서 그 구조체를 전부 복사하느라고 그렇다는 것이다. (92만번 복사하면 꽤 크다.)

```

8   Vector y0 = network_forward(*net, dataset[i]);
9   // CROWN backward bound or forward bound 계산
10  switch(method){
11  case 0: {
12      ForwardBoundResult fwd = lirpa_forward_bound_impl(*net, dataset[i], eps_f, false, false, true);
13      // Top-k 인증 판정
14      if (certify_topk(y0, fwd.final_lower, fwd.final_upper, k))
15          ++t_count;
16      else
17          ++f_count;
18      break;
19  }
20  case 1: {
21      BackwardBoundResult bwd = lirpa_backward_bound(*net, dataset[i], eps_f, false, false);
22      // Top-k 인증 판정
23      if (certify_topk(y0, bwd.final_lower, bwd.final_upper, k))
24          ++t_count;
25      else
26          ++f_count;
27      break;
28  }
29  default:
30      break;
31  }
32  }

```

그래서 이런식으로 안에서 선언과 동시에 만들어지도록 해봤다.

- 참고로 switch 안의 선언문은 중괄호로 저렇게 덮어주지 않으면 안되더라

```

C:\Users\User\Desktop\cuda\crown\testing(present)>nvcc -Xcompiler "/utf-8" -Xlinker "/STACK:134217728" -arch=sm_89 crown_test_all_data.cu -o crown_test_all_data_backward.exe
crown_test_all_data.cu
crown_test_all_data.cu(250): warning #546-D: transfer of control bypasses initialization of:
    variable "fwd" (declared at line 252)
    variable "bwd" (declared at line 260)
    switch(method){
        ^
Remark: The warnings can be suppressed with "-diag-suppress <warning-number>"
crown_test_all_data.cu(250): warning #546-D: transfer of control bypasses initialization of:
    variable "fwd" (declared at line 252)
    variable "bwd" (declared at line 260)
    switch(method){
        ^
Remark: The warnings can be suppressed with "-diag-suppress <warning-number>"
tmpxft_0000025c_00000000-7_crown_test_all_data.cudafe1.cpp
crown_test_all_data.cu(259): error C2360: 'fwd' 초기화가 'case' 레이블에 의해 생략되었습니다.
crown_test_all_data.cu(252): note: 'fwd' 선언을 참조하십시오.
crown_test_all_data.cu(267): error C2361: 'bwd' 초기화가 'default' 레이블에 의해 생략되었습니다.
crown_test_all_data.cu(260): note: 'bwd' 선언을 참조하십시오.
crown_test_all_data.cu(267): error C2361: 'fwd' 초기화가 'default' 레이블에 의해 생략되었습니다.
crown_test_all_data.cu(252): note: 'fwd' 선언을 참조하십시오.

```

fwd, bwd 초기화가 해당 레이블에 의해 생략되었다.. 즉 main 함수 scope의 선언문은 무조건 선언이 되어야하는데 레이블에 의해 그 부분이 생략되고 있으니 작은 scope를 만들어준 것.

하여튼 이렇게 해서 결과를 봤다.

```

eps= 1.0e+00: T= 0 F=40000 ratio=0.000
total elapsed: 1634.61s
results saved to results_cuda.csv

```

음.. 준수한 결과다. ⇒ 이러면 2100s 초 나오는 문제도 원인 해결 완료

=====

근데 아까 커맨드 라인 인자 없이 돌렸을 때는

```
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1560.37s
results saved to results_cuda.csv
```

1560s도 나왔단 말이지..

이건 뭐지? 100초 정도 차이나는 건.....?

갑자기 또 2187초 뜨냐... 뭐지..

...? 또 1636초..

```
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1342.47s
results saved to results_cuda.csv
```

forward는 갑자기 또 1342s 까지도 떨어지네.. 뭐냐 도대체 크아악 (아마 이걸 앞서 말했던 값에 의한 복사를 해결해서?)

```
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1561.72s
results saved to results_cuda.csv
```

(이게 실행인자 없는 버전 **backward**)

```
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1460.60s
results saved to results_cuda.csv
```

(근데 실행인자 없는 버전 **forward**)

?????? 이걸 또 실행인자 있는게 더 빨라

```
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1564.18s
results saved to results_cuda.csv
```

다시 실행 인자 있는 **backward**

1564s 정도로 비슷하다.

```

eps= 9.0e-03: T= 0 F=40000 ratio=0.000
eps= 1.0e-02: T= 0 F=40000 ratio=0.000
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1447.17s
results saved to results_cuda.csv

```

(실행 인자 있는 forward)

```

eps= 9.0e-03: T= 0 F=40000 ratio=0.000
eps= 1.0e-02: T= 0 F=40000 ratio=0.000
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1360.22s
results saved to results_cuda.csv

```

(실행 인자 있는 forward)

```

eps= 1.0e-02: T= 0 F=40000 ratio=0.000
eps= 1.0e-01: T= 0 F=40000 ratio=0.000
eps= 1.0e+00: T= 0 F=40000 ratio=0.000

total elapsed: 1375.97s
results saved to results_cuda.csv

```

(실행 인자 있는 forward)

새로 페이지를 파서 확인해보기로

=====

정리하면 현재 의문

1. 단일 데이터 테스트(**forward/backward** 3배 차이)와 달리 다중 데이터 테스트만큼의 **forward** 성능감소가 어디서 일어나는가?
2. 구조체 값에 의한 복사를 제거하고 나서 **backward**가 다시 2100s정도로 튀는 문제가 있었는데, 일단 전체적으로 시간이 줄긴 했는데 다시 튼건 뭇때문에?
3. 실행 인자 추가 + **switch**문 사용이 실제로 성능에 영향을 준건지? (**switch** 사용하고 좀 느려진 것 같기도 하니까)

=====

8번째 세미나 이후... 많이 혼났으니 이때를 절대 기억할 것.

랩 미팅 이후 할 것 개선점

발표 관련해서 지적받은 부분

1. 자료를 비교하려면 한눈에 슬라이드에서 차이가 들어오게 구성해야한다. (특히 표를 넣을때는 주의해서, 최대한 이해가 쉽게 넣어보자, 숫자하나하나가 데이터에 들어오게라던가, 내가 강조할 부분을 따로 계산해서 넣어놓는다던가)
(지금까지 색깔만 했었는데 좀 더 내가 표에서 말하고 싶은 부분을 강조하자)
2. 웬만하면 대본을 보지 않고 그냥 내가 말하고 싶은 부분을 발표자료에 넣는것으로 해보자 .. (그냥 대사를 박아서 따라 읽는것도.. ㄱㅅ)

다음주에 해야할 것.. 또는 보완할 것

1. **Compute Throughput**과 **Memory Throughput**의 정확한 정의(정확히는 수식)
알아보기 : **memory throughput**의 비율 감소 원인엔 뭐가 있을까?
⇒ 아 맞다.. **SM**이 너무 바빠서 메모리 병목이 생기는 경우...
2. **forward, backward** 92만번 실행에 대해 가끔 튀는 경우가 있는데 그거 평균, 분산을 구해보자 ← 측정완료 평균, 분산만 슬라이드에 넣으면 됨
3. 추론 + **bound** + 검증 모두 합쳐서 측정하고 있던 걸 나눠서 각각 측정하자
 - a. 일단 92만번의 **forward, backward** 측정하기 ← **20**번씩 측정 완료
 - b. 단일 데이터(**optimizing.exe**)에 대해서도 **warm up**이 얼마나 영향미치는지 측정하기 ← 측정 & 검증 완료 (이건 근데 발표에서 교수님이 초기화 비용때문이겠지 라고 말씀하셔서.. 일단 자투리로 넣던가 하자)
 - c. **sparse.py**도 나눠서 측정하기 ← 검증팀에 물어봤는데 따로 측정한 건 없다고 해서 **forward**만 2번 더 측정하자
 - d. 이후 **sparse.py**와 **forward, backward** 기준으로 각 평균시간이 몇 배 차이나는지 검사하기
4. 신경망 검증팀과 얘기해서 **forward, backward**의 검증 비율 결과 차이가 이정도 나는게 맞는지 검사 하자 + 신경망 검증팀도 **sweep**으로 해서 추론 + **bound** + 검증 92만번의 사이클을 한번에 계산했는데.. 이것도 물어보자 ← 확인 결과 둘 다 맞다고 한다, (**forward**와 **backward**의 차이, **sweep** 사이클)
5. **tensorRT** ? **Nvidia**에서 제공하는 **sdk**인데 최적화를 잘해준다고 한다.. 이걸로 컴파일 한 걸 테스트하고 내가 짠 **nvcc** 컴파일과 시간 비교하는 것도 좋을듯?

그래서 ..

먼저 한 것..

```

for (int i = 0; i < N; ++i) {
    // — [1] 추론 —————
    // 신경망 정방향 통과
    auto t0 = std::chrono::high_resolution_clock::now();
    Vector y0 = network_forward(*net, dataset[i]);
    auto t1 = std::chrono::high_resolution_clock::now(); // 추론 끝 시간
    time_infer_total += std::chrono::duration<double>(t1 - t0).count(); // 추론 시간 누적

    // — [2] Bound 계산 + [3] 검증 —————
    // CROWN backward bound or forward bound 계산
    // (각 case 안에서 직접 초기화 → NRVO 적용, 4MB+ 구조체 복사 0회)
    switch(method){
        case 0: {
            ForwardBoundResult fwd = lirpa_forward_bound_impl(*net, dataset[i], eps_f, false, false, true);
            auto t2 = std::chrono::high_resolution_clock::now(); // bound 계산 끝 시간
            time_bound_total += std::chrono::duration<double>(t2 - t1).count(); // bound 시간 누적
            // Top-k 인증 판정
            if (certify_topk(y0, fwd.final_lower, fwd.final_upper, k))
                ++t_count;
            else
                ++f_count;
            auto t3 = std::chrono::high_resolution_clock::now(); // 검증 끝 시간
            time_certify_total += std::chrono::duration<double>(t3 - t2).count(); // 검증 시간 누적
            break;
        }
        case 1: {
            BackwardBoundResult bwd = lirpa_backward_bound(*net, dataset[i], eps_f, false, false);
            auto t2 = std::chrono::high_resolution_clock::now(); // bound 계산 끝 시간
            time_bound_total += std::chrono::duration<double>(t2 - t1).count(); // bound 시간 누적
            // Top-k 인증 판정
            if (certify_topk(y0, bwd.final_lower, bwd.final_upper, k))
                ++t_count;
            else
                ++f_count;
            auto t3 = std::chrono::high_resolution_clock::now(); // 검증 끝 시간
            time_certify_total += std::chrono::duration<double>(t3 - t2).count(); // 검증 시간 누적
            break;
        }
        default:
            break;
    }
}

```

각 추론, bound 계산, 검증에 끝마다 시간을 기록해서(E2E) 각각 시간을 측정하도록 하였다..

끝나고 보니 elapsed 타임(92만 번 계산 시간)과 미세한 오차가 있는데, 이건 그냥 저 **3**개의 누적 시간을 더한 게 더 올바른 시간 같아서 그걸 넣기로 함

그리고 저렇게 해서 각 forward, backward 20번씩 측정 완료
(튀는 값 있긴 있는데, 그건 각 **20**번 실행 시간 평균이랑 분산 구해서 슬라이드에 넣을 예정)

=====

b 과정 : 단일 데이터 측정 에 대해서 검증하기

먼저 warm up 코드 넣었다.

```

175
176 //=====
177 // warm up 하기
178 network_forward(*net, x0);
179 //lirpa_backward_bound(*net, x0, eps, false, false);
180 lirpa_forward_bound_impl(*net, x0, eps, false, false, true);
181 // =====

```

```

9 // 시간 측정 시작 (신경망 정방향 통과 및 CROWN)
0 auto t_start = std::chrono::high_resolution_clock::now();
1
2 // 1. 일반 예측값 확인 (신경망 정방향 통과)
3 Vector y = network_forward(*net, x0);
4 auto t_infer = std::chrono::high_resolution_clock::now();
5 double time_infer = std::chrono::duration<double, std::milli>(t_infer - t_start).count();

```

측정 시작을 기준으로 추론 이후 타임스탬프, 이후 추론 시간 계산

```

// 2. CROWN (Backward Bound) 호출
// 여기서 선언시 BackwardBoundResult 빈 공간(4MB 할당 + 자잘한 벡터들까지 해서 넉넉히 0.25MB )
// 내부 함수에 진입해서 보면 거의 64MB가 필요함 (함수 주석 참고) <= 근데 64MB 안되서 128MB로 함
// 왜인지는 모르겠다 너무 함수가 복잡해져서..
//BackwardBoundResult bwd = lirpa_backward_bound(*net, x0, eps, false, false);

// 신경망 + forward 결과만 보면 7ms 초반 ~ 8ms 초반 정도
ForwardBoundResult bwd = lirpa_forward_bound_impl(*net, x0, eps, false, false, true);
auto t_bound = std::chrono::high_resolution_clock::now();
double time_bound = std::chrono::duration<double, std::milli>(t_bound - t_infer).count();

```

bound 도 계산

```

std::cout << std::fixed << std::setprecision(4); // 시간 초는 소수점 4자리까지 출력
std::cout << "calc success" << std::endl;
std::cout << "Elapsed time: " << elapsed_ms << " ms" << std::endl;
std::cout << "Inference time: " << time_infer << " ms" << std::endl;
std::cout << "Bound time: " << time_bound << " ms" << std::endl;

std::cout << std::fixed << std::setprecision(13); // 결과는 오차 검사를 위해 길게

```

출력해주기

실행 결과 보자면

```

=====
calc success
Elapsed time: 1.6966 ms
Inference time: 0.1417 ms
Bound time: 1.5547 ms
Output Dimension: 16

```

이게 forward 계산 시간

평균: 1.342395

← 이게 20번 92만 번 테스트(test_all_data)의 평균 bound

```

Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 1.9254 ms
Inference time: 0.1404 ms
Bound time: 1.7846 ms
Output Dimension: 16

```

이게 **backward** 계산 시간

평균: 1.563180952 ← 이게 20번 92만 번 테스트(**test_all_data**의 평균 **bound**

단일 테스트에서 뒀을 때도 좀 0.2ms 정도 느리다. 이게 왜 이렇게 되었을 지 고민을 해봤는데.. 생각해보니 교수님께서 그런 말을 하셨다.

40000개의 데이터중에도 계산이 더 빠른 데이터가 있고, 느린 데이터가 있을것..

저기서는 평균으로 나와서 그럴지만(아마 빠른 데이터가 느린 데이터보다 많았던 거 아닐까), 저 단일 데이터는 상대적으로 느렸을 수도?

(**test_all_data.bin**에서 단일 데이터를 다르게 뽑아서 검증해볼까, 시간이 얼마나 달라지는지)

⇒ 그래서 해봤다.

근데

평균: 1.91838356 개수: 40000 합계: 76735.3424

평균이 1.91 ms 정도..

좀 다르긴 한데..

너무 깊게 파고들지 말자.. 중요한 건 초기 초기화 비용으로 인해서 3배차이 났던 게 맞는지 검증하려고 시작한 거니까 ..

그러면 다시 돌아가서

아래가 **backward** 측정 시간 (**warmup** 한번)

```

calc success
Elapsed time: 1.9171 ms
Inference time: 0.1409 ms
Bound time: 1.7760 ms
Output Dimension: 16

```

아래가 **forward** 측정 시간 (**warmup** 한번)

```

=====
Starting CROWN Verification (eps = 1e-06) mempool + warmup
=====
calc success
Elapsed time: 1.9759 ms
Inference time: 0.1867 ms
Bound time: 1.7889 ms
Output Dimension: 16

```

별로 차이가 안난다..

그러면 일단

초기화만 하면 **forward, backward**의 **bound** 계산 시간은 비슷하다는 것!
(한 **0.2ms** 정도 차이남)

=====

여기서 적절한 기준을 다시 세우기로 했다
gpu 벤치마크 모범 사례를 따라서

Nvidia의 warm up 가이드라인 을 세우고

1. 실제 사이클 시간만 측정 (가중치 로드 memcpy 등은 포함 x)
2. warm up 한번 하기
3. CV를 통해서 스파이크, 분산 정도를 규명할 것

추론, bound 계산, 검증 3가지 값을 나눠서 측정하기로 했다..

근데 웬 일? warmup 하니까 걸리는 시간 및 각 평균 시간이 더 늘어남 ...

어느정도냐면.. forward 가 warm up 이전 backward 급 속도가 나을정도..

음... 이게 잘 모르겠다..

의문점 : **warm up**을 해도 스파이크 데이터가 뜨고, 심지어 가끔은 **10**번 측정했을 때 평균 시간이 느려지는 문제 생김

규명할 원인 두가지가 늘어난 느낌.... 이런

그래도 곳곳이 측정했더니

1. 일단 warm up도 warm up 이전 버전이랑 측정 시간에서 큰 차이 나지 않음
2. 스파이크가 안뜰 때의 시간은 오히려 더 안정적인듯 (변동 계수가 좀 더 낮은 느낌)

그래서

sparse.py, CUDA 평균 bound 계산 시간 (n = 5)

CROWN method	sparse.py (ms)	CUDA (ms)	bound 계산 성능	추론 + bound + 검증
forward	6.951	1.307	5.32x (81.2% 단축)	4.86x (79.4% 단축)
backward	8.044	1.519	5.30x (81.1% 단축)	4.89x (79.6% 단축)

sparse.py 와 CUDA의 CROWN bound 계산 평균 1회 결과 표

5.3 배 정도 차이나는 것을 확인했고

저 스파이크 문제 + 평균 시간의 분포가 살짝 올라간 문제는 흠.. 클럭 고정 한 뒤 다시 측정해보거나 gpu 사용량을 측정해보거나 하면 될듯? (교수님께서는 CV 가 아주 간헐적으로 튀어서 그렇다고 말씀드렸으니 발표에 담을 것은 아니고)

=====

9주차 세미나 이후 해야 할 것

음 ..

1. 스파이크 문제.. 여전히 규명하고 싶다.. ⇒ gpu 클럭 고정 or gpu 온도 (사용량) 등을 측정해보면 정확히 원인을 규명할 수 있지 않을까?
2. 안티그래비티로 시도해 볼 만한 내용들 정리해놨으니 그거 보고 이번주 발표할 내용을 정리해보자

배칭 시스템 구현했더니 3배나 빨라졌다.

##### backward	40000	23	481.7157	1.3569	479.6443	0.6957	0.0015	0.5214	0.0008
##### forward	40000	23	438.3345	1.599	435.8792	0.6724	0.0017	0.4738	0.0007

물론.. 실시간 환경에서는 이렇게 데이터셋을 짹 짹 채워서 넣지는 못한다만..

일단 branch를 따로 뒀서 저장해놓기로 했다.
(temp_batching)

지금까지 해본 최적화

1. 제로 memcpy
2. 커널 자체 실행 횟수 감소
 - a. 커널 퓨전
 - b. 커널 graph
3. GPU 아키텍처의 SM 구조 고려하기 (FP64 -> FP32 , double -> float)

추가 최적화 계획

그리고 실제로 수행한 것

4. **cudaGraph**를 이용한 커널 캡처 (커널 런치 오버헤드 최소화) ← 현재 92만 번의 입력값을 계산하면서 1번의 **CROWN** 계산 내에서도 수십번의 커널이 호출되므로 **graph** 캡처를 하게되면 이 수십번의 커널 호출을 하나의 호출로 압축 가능 (즉 많은 커널 호출 횟수로 인한 오버헤드가 있을 시 고려할 수 있다) (물론 이건 커널 자체 최적화까지 끝냈을 때 고려 가능, 하나의 스냅샷을 만드는 기능이므로)

graph 최적화 과정 & 결과 보고서

앞으로 고려해볼 만한 것

5. 배칭 (싱글 스트림이 아닌 멀티 스트림, 데이터 하나씩 주지 말고 여러개 묶어서 넣으면 병렬처리가 가능하니까.) (기존 데이터셋이 준비된 실험 환경에서는 단일 스트림보다 3배 시간 빨라짐, (25 분 -> 8분))

여기서 **cudaGraph**를 통해 추론, **bound** 따로 / 추론 + **bound** 한번에 하는 것을 따로 캡처해서 커널 런치 비용을 최소화 해봤다.

##### backward_cuda_graph	40000	23	1114.119	119.9149	990.9191	3.0148	0.1303	1.0771	0.0033
---------------------------	-------	----	----------	----------	----------	--------	--------	--------	--------

한 400초 정도 줄어든 듯?

(이게 추론이랑 , **bound** 랑 따로 캡처했을 때 기준임)

=====

이전에 시도한 배칭으로 데이터셋을 통째로 넘겨주는 건 실시간 환경이 아니라 판단해서 대신 데이터셋이 있는 부분을 **pinned Memory**로 지정하고 메모리 복사 속도를 최대로 늘림 (그 과정에서 **cudaMemcpyAsync**를 쓰기도 하고)

```
// 실시간 PCIe H2D 전송 최적화: Host Memory Pinning (cudaHostRegister)
// pinned memory 를 써서 GPU가 CPU 메모리에 직접 접근할 수 있도록 하여 데이터셋 전송 속도 향상
// 왜 이걸 했냐 하면 실제 상황 최대한 재현을 위한 것 (5 , 6G 환경에서의 실시간 입력 속도를 최대한 재현하기 위함)
bool dataset_pinned = false;
if (N > 0) {
    // cudaHostRegister : 일반 메모리로 만들어진 메모리 영역을 복사 없이 pinned Memory 로 승격시켜줌
    // 인자로 시작 포인터 dataset.data() / 등록할 메모리 크기 (N * sizeof(Vector))
    // 플래그 cudaHostRegisterDefault (가장 일반적인 pinning 옵션)
    cudaError_t reg_err = cudaHostRegister(dataset.data(), (size_t)N * sizeof(Vector), cudaHostRegisterDefault);
    if (reg_err == cudaSuccess) { // 여기서 cudaSuccess는 cuda에서 쓰는 성공 고유 상태코드
        dataset_pinned = true;
        std::cout << "Dataset host memory pinned via cudaHostRegister ("
            << ((size_t)N * sizeof(Vector)) / (1024 * 1024) << " MB, zero CPU blocking DMA enabled)." << std::endl;
    } else {
        std::cout << "Notice: cudaHostRegister skipped (" << cudaGetErrorString(reg_err) << ")." << std::endl;
    }
}
}
```

+

커널 memcpy에서 기존에 MAXDIM으로 무조건 512 개의 float만큼 복사했는데, 이걸 고쳤다..

필요한 만큼의 데이터 크기만 복사해서 주도록 (근데 여기서 cpu 계산 오버헤드가 더 큰 것 같기도 하고 , 왜냐하면 시간이 늘었음)

```
// 이것도 16개 노드 * 두개의 바운드 해서 총 32 (* 4byte)만 딱 가져오려고
const size_t out_bytes = sizeof(int) + (size_t)out_dim * sizeof(float);
cudaMemcpyAsync(h_final_lower, d_final_lower, out_bytes, cudaMemcpyDeviceToHost, stream);
cudaMemcpyAsync(h_final_upper, d_final_upper, out_bytes, cudaMemcpyDeviceToHost, stream);
cudaStreamSynchronize(stream);
```

예를 들어 이런 거,

자세한 내용은 아래 문서 링크 참조

[단일 샘플 빠르게 입력](#)

##### forward_cuda_graph	40000	23	983.5557	111.8191	869.6823	1.958	0.1215	0.9453	0.0021
##### backward_cuda_graph	40000	23	1134.724	111.6514	1021.007	1.9707	0.1214	1.1098	0.0021
##### forward_cuda_graph_fused	40000	23	1006.863	0	1004.825	1.9407	0	1.0922	0.0021
##### backward_cuda_graph_fused	40000	23	1116.847	0	1114.759	1.9908	0	1.2117	0.0022
실시간 멀티스트림									
##### forward_cuda_graph	40000	23	1055.282	131.7986	920.8438	1.5972	0.1433	1.0009	0.0017

위의 forward_cuda_graph 가 983s 정도가 전체 시간이고 , 아래의 1055가 cpu에서 필요한만큼만 계산한 뒤 복사한 시간임

72초 차이 나는데 (더 늦어짐..)

일단 마지막 1055의 자세한 측정 결과를 보면

```

total elapsed: 1055.28s

--- Phase Timing Breakdown (all eps x all data) ---
infer   : 131.799s (12.5%)
bound   : 920.844s (87.3%)
certify  : 1.597s (0.2%)

=== Real-Time Single-Sample (B=1) Latency Analysis ===
Evaluated Samples : 100000
Min Latency       : 1092.30 us
Mean Latency      : 1145.24 us (1.15 ms)
Median (P50)     : 1136.80 us
P95 Tail Latency : 1179.00 us
P99 Tail Latency : 1311.90 us
Max Latency       : 7830.90 us
Jitter (StdDev)   : 60.33 us
Throughput        : 873.18 samples/sec
Pure GPU Execution: 953.70 us (last sample)

=====
results saved to results_cuda.csv
timing log appended to timing_log_crown.csv

```

(평가 샘플이 10만개밖에 안되는 이유는 표본 측정으로 하려고..)

흠.. cudaEvent를 추가해서 그런 걸수도.. < 일단 이건 시스템 인자 넣어서 제어해보는 중

```

204 + int      measure_gpu = (argc > 8 && strlen(argv[8]) > 0) ? atoi(argv[8]) : 1;
205 + // measure_gpu: cudaEvent 하드웨어 타이머 측정 제어 시스템 인자
206 + // 0 = 비활성화 (Off, 드라이버 오버헤드 0, 최고 속도)
207 + // 1 = 마지막 샘플만 1회 측정 (Last sample only, 전체 루프 오버헤드 0초 + 맨 마지막 Pure GPU 시간 리포트, 기본값)
208 + // 2 = 매 샘플마다 측정 (All samples, 92만 번 전체 정밀 측정, 호출당 20~50us 드라이버 오버헤드 발생 주의)

```

그럼 원인으로 나온 것

1. cudamemcpy로 복사할 메모리 계산 cpu 계산 때문?
2. cudaEvent 커널 측정 때문?
3. 진짜 gpu 클럭 때문?

이건 다음주에 발표하자 (추석이니까 발표할거 만들어야하니까..)

혹시 몰라서 커밋 이전거 한번 돌려봤는데 (graph만 적용한 버전)
역시 그게 더 빠른데..

흠 뭐때문이지

근데 분명한 건 topk 속도는 빨라져서 이건 빼먹을 수 있을지도 모른다.

빼먹을 부분 정리하면

1. 데이터셋 pinnedMemory
2. 검증 (heap -> stack) 배열
3. cudaEvent는 결국 필요해 (Nsight Compute 분석 하려면..)

그럼.. 결국 지워볼 만한 곳은 cpu를 통해서 필요한 만큼만 계산하는 부분... 이부분밖에
없는데?

그래서 평균으로 측정을 해봤다

timestamp	method	N	eps_count	total_s	infer_s	bound_s	certify_s	avg_infer_ms	avg_bound_ms	avg_certify_ms
#####	forward_cuc	40000	23	1035.2962	119.6961	911.4919	2.8799	0.1301	0.9908	0.0031
#####	backward_c	40000	23	1123.7942	113.2002	993.6226	2.0701	0.123	1.08	0.0023
#####	forward_cuc	40000	23	985.8562	112.0688	872.9448	0.7701	0.1218	0.9489	0.0008
#####	forward_cuc	40000	23	1052.5192	111.2484	940.4763	0.7258	0.1209	1.0223	0.0008
#####	forward_cuc	40000	23	976.4102	110.8478	864.7812	0.7137	0.1205	0.94	0.0008
#####	forward_cuc	40000	23	1027.604	111.162	915.6468	0.7254	0.1208	0.9953	0.0008
#####	forward_cuc	40000	23	1037.4762	111.8296	924.8194	0.7549	0.1216	1.0052	0.0008
#####	forward_cuc	40000	23	982.9074	111.2852	870.8195	0.733	0.121	0.9465	0.0008
#####	forward_cuc	40000	23	1007.0036	110.8921	895.3312	0.7128	0.1205	0.9732	0.0008
#####	backward_c	40000	23	974.9798	110.9293	863.2666	0.7153	0.1206	0.9383	0.0008
#####	forward_cuc	40000	23	974.3991	110.769	862.8576	0.7056	0.1204	0.9379	0.0008
#####	forward_cuc	40000	23	1008.6291	110.7722	897.0824	0.7066	0.1204	0.9751	0.0008
#####	평균	920000		1002.77848	111.18044	890.80258	0.72632	0.12085	0.96827	0.0008
timestamp	method	N	eps_count	total_s	infer_s	bound_s	certify_s	avg_infer_ms	avg_bound_ms	avg_certify_ms
#####	backward_c	40000	23	1133.8077	110.7947	1022.221	0.7237	0.1204	1.1111	0.0008
#####	backward_c	40000	23	1112.32	110.6234	1000.9186	0.71	0.1202	1.088	0.0008
#####	backward_c	40000	23	1112.263	110.6063	1000.8752	0.7141	0.1202	1.0879	0.0008
#####	backward_c	40000	23	1132.4453	110.7491	1020.9089	0.719	0.1204	1.1097	0.0008
#####	backward_c	40000	23	1155.8213	117.6799	1036.8659	1.1365	0.1279	1.127	0.0012
#####	backward_c	40000	23	1114.5961	119.9604	993.1675	1.287	0.1304	1.0795	0.0014
#####	backward_c	40000	23	1145.7508	119.1598	1025.1157	1.2969	0.1295	1.1143	0.0014
#####	backward_c	40000	23	1141.1841	117.6279	1022.1586	1.2246	0.1279	1.111	0.0013
#####	backward_c	40000	23	1190.0012	118.4774	1070.1121	1.2377	0.1288	1.1632	0.0013
#####	backward_c	40000	23	1157.8767	118.2467	1038.2333	1.2267	0.1285	1.1285	0.0013
#####	평균	920000		1139.60662	115.39256	1023.05768	1.02762	0.12542	1.11202	0.00111

cudaGraph만 적용된 버전

timestamp	method	N	eps_count	total_s	infer_s	bound_s	certify_s	avg_infer	avg_bound	avg_certify	rmeasure
#####	forward_cuc	40000	23	1052.3061	133.6387	916.332	1.9455	0.1453	0.996	0.0021	1
#####	forward_cuc	40000	23	1009.8559	132.8836	874.7081	1.9106	0.1444	0.9508	0.0021	1
#####	forward_cuc	40000	23	1009.8484	132.4788	875.045	1.951	0.144	0.9511	0.0021	1
#####	forward_cuc	40000	23	1010.2909	132.6513	875.359	1.92	0.1442	0.9515	0.0021	1
#####	forward_cuc	40000	23	1010.9938	133.5059	875.1523	1.9607	0.1451	0.9513	0.0021	1
#####	forward_cuc	40000	23	1079.1851	132.7583	944.0919	1.9426	0.1443	1.0262	0.0021	1
#####	forward_cuc	40000	23	1080.5696	133.3903	944.8346	1.9649	0.145	1.027	0.0021	1
#####	forward_cuc	40000	23	1033.3268	133.5921	897.4392	1.9424	0.1452	0.9755	0.0021	1
#####	forward_cuc	40000	23	1010.16	132.6512	875.1641	1.9525	0.1442	0.9513	0.0021	1
#####	forward_cuc	40000	23	1001.7292	132.2964	867.0931	1.95	0.1438	0.9425	0.0021	1
#####	평균			1029.827	132.985	894.522	1.94402	0.14455	0.97232	0.0021	
timestamp	method	N	eps_count	total_s	infer_s	bound_s	certify_s	avg_infer	avg_bound	avg_certify	rmeasure
#####	backward_c	40000	23	1131.57	133.4019	995.8241	1.972	0.145	1.0824	0.0021	1
#####	backward_c	40000	23	1138.2005	132.3807	1003.506	1.9248	0.1439	1.0908	0.0021	1
#####	backward_c	40000	23	1137.9269	132.2946	1003.292	1.9528	0.1438	1.0905	0.0021	1
#####	backward_c	40000	23	1139.5205	133.1567	1004.038	1.943	0.1447	1.0913	0.0021	1
#####	backward_c	40000	23	1139.4207	133.1682	1003.891	1.9632	0.1447	1.0912	0.0021	1
#####	backward_c	40000	23	1138.8184	132.6175	1003.855	1.9601	0.1441	1.0911	0.0021	1
#####	backward_c	40000	23	1142.9903	134.2504	1006.365	1.9868	0.1459	1.0939	0.0022	1
#####	backward_c	40000	23	1138.9689	132.9438	1003.672	1.9536	0.1445	1.0909	0.0021	1
#####	backward_c	40000	23	1138.4635	132.4382	1003.665	1.9747	0.144	1.0909	0.0021	1
#####	backward_c	40000	23	1139.0179	132.9698	1003.684	1.9863	0.1445	1.091	0.0022	1
#####	평균			1138.49	132.962	1003.18	1.96173	0.14451	1.0904	0.00212	

이게 pinned Memory 추가 + cudaEvent 제어 + 필요한 만큼 계산해서 D2H memcpy + certify topk 자료구조 스택화이고

(graph와 비교해서 단일 스트림 입력 복사 최적화를 이야기 하자면)

1. forward에선 전체적(추론, bound, 검증)으로 graph 단일 적용이 우수하다, 특히 infer_s에 대해 대해서는 20초 차이 남
2. 그런데 backward를 보면 total 시간이 비슷함, 그 이유는 infer에서 깎아먹은 20초를 bound에서 graph보다 20초 빨리 수행하고 있다는 점..

그래서 일단 유지 하기로 했다.

1. 굳이 하자면 infer는 어쨌든 계산이 필요없을 것 같긴해서 (vector라서 크지 않다는 점) 크기 계산을 주석처리 한다던가
2. certify에서는 .. 흠.. 잘 모르겠다, 다시 heap으로 바꿔야하나?

=====

10주차 세미나 이후 생각해볼 것

1. **backward_only CUDA**로 구현하기 ⇒ 커널 구현 완료 , 최적화 적용 여부 탐색중
2. **cudaGraph** 에 대한 원리 자세히 알아보기
3. ~~관화씨와 소통해서 auto_lirpa 모델 얘기하기~~ ⇒ 얘기 했고 **repo** 받았다. , 데이터셋, 모델은 동일하다고 한다.
4. 오늘(9월 21일) 16시 , (다음주?) 화요일 오후 7시 반? 미팅
5. 배칭 + 다중 스트림 관련해서 실제 환경과의 괴리? ⇒ 다만 얻은것은 일단 **gpu** 자원이 남는다는 것, 그리고 단일 스트림과 단일 데이터 복사가 현재 큰 병목을 만들고 있다는 것
6. ~~컴파일러 팀에 모델 공유하기~~ ⇒ 공유 완료

발표와 관련해서는

7. 발표를 탐다운으로 구성 - 코드는 필요한 만큼만(내가 설명하려는 핵심에 필요할 경우에만.), 핵심적인 문제에 대해서 (추상화 할 필요가 있음)

일단 **repo**를 받아서 실행해보자

https://github.com/horangahor/antenna_auto_lirpa

최적화 기법

1. 공유 메모리 타일링 (Shared Memory Tiling):

현재 행렬곱 커널은 글로벌 메모리에서 직접 원소를 읽습니다. **L1** 공유 메모리(**__shared__**)에 타일 단위로 올려 재사용하면 글로벌 메모리 대역폭 병목을 더 줄일 수 있습니다.

2. 루프 언롤링 (**#pragma unroll**): (새로 알게 된 것)

행렬곱 내부 루프의 분기 검사 비용을 줄이고 명령어 병렬성(ILP) 증대.

3. 고속 내장 수학 함수 (**Fast Math / Intrinsics**): (새로 알게 된 것)

컴파일러 옵션 **-use_fast_math** 또는 **__expf()** 등 하드웨어 전용 특수 함수 사용.

을 추가로 고려해볼 만 하다

그리고 명시적으로는 안해본 것

1. **warp divergence** (스레드 분기 최소화)
2. 비동기 스트림
3. 블록 사이즈 계산
4. 메모리 **coalescing**
5. 타일링 (위에서 언급함)

=====