

SW 연구 및 시스템 설계 노트 (Research Proposal Notes)

연구 과제: 딥러닝 형식 검증 LiRPA/CROWN 알고리즘의 GPU 가속화 및 CUDA 커널 최적화 설계

1. 연구 배경 및 해결하고자 하는 문제 (Research Problem)

신경망의 안전성 및 강인성(Robustness)을 수학적으로 보증하는 LiRPA (Linear Relaxation-based Perturbation Analysis) 및 CROWN 알고리즘은 심층 신경망의 레이어별 Bound를 역전파(Backward iteration)하며 계산하는 복잡한 수치 연산을 요구한다. 기존 C++ 기반 구현체(lirpa_forward_backward_fc_array.cpp)는 CPU 단일/다중 스레드 환경에서 동작하여 고차원(FC 레이어 뉴런 수 증가) 환경에서 연산 지연시간이 기하급수적으로 증가하는 치명적인 병목 현상이 발생한다.

- 기존 방식의 한계: 고차원 행렬 곱셈 및 반복적인 상/하한 Bound 갱신 연산이 CPU 메모리 대역폭 한계에 부딪힘.
- 목표: C++ 기반 Bound Propagation 핵심 연산 루프를 NVIDIA CUDA 커널 및 cuBLAS 가속 아키텍처로 전면 재설계.

2. 제안 방법론 및 아키텍처 (Proposed Methodology)

본 연구에서는 CROWN 역방향 바운드 전파(Backward Only Iteration)의 연산 특성을 분석하여 계층별 최적화 파이프라인을 제안한다:

- 커널 분리 및 GPU 오프로딩: 선형 변환 및 활성화 함수 상/하한 기울기 계산을 개별 CUDA 디바이스 커널(kernel function)로 전환.
- cuBLAS & cuSPARSE 하이브리드 연산: 고밀도 가중치 행렬 곱셈에는 cuBLAS(cublasDgemm)를 적용하고, 희소 행렬 연산에는 cuSPARSE spMM을 적용하여 0이 다수 포함된 이완 행렬의 불필요한 연산을 건너뛴다.
- CUDA 메모리 풀(Memory Pool) 관리: 반복적인 cudaMalloc/cudaFree로 인한 드라이버 오버헤드를 방지하기 위해 정적 메모리 풀을 사전 할당(crown_test_preload_fix)하여 디바이스 메모리 재사용 극대화.
- 비동기 스트림 및 동기화 최적화: 불필요한 cudaDeviceSynchronize를 최소화하고 계산과 메모리 전송을 오버랩.

3. 핵심 기여점 (Key Contributions)

- CROWN 신경망 형식 검증 알고리즘의 최초 CUDA 병렬화 아키텍처 설계 명세 수립.
- cuBLAS 라이브러리와 커스텀 CUDA 커널 간 메모리 오버헤드 최소화 브릿지 구현.
- 대규모 가중치(최대 40,000차원) 처리 시 GPU 메모리 절약형 청크 분할 기법 제안.

4. 연구 가설 및 전제조건 (Assumptions)

- 대상 신경망은 Fully-Connected(FC) 레이어 기반이며, 각 레이어의 가중치 행렬은 GPU VRAM(최소 8GB 이상)에 상주 가능하다고 가정함.

- 입력 섭동 범위(Epsilon)는 런타임 인자로 동적 변경 가능해야 함.
- 연산 정밀도는 IEEE 754 배정밀도(double precision)를 유지하여 수학적 사운드니스(Soundness)를 보장함.