

실증 검증 및 벤치마크 리포트 (Empirical Validation Report)

테스트 대상: CROWN CUDA 가속 엔진 (my_lirpa_op_only_GPU / my_lirpa_mempool_cuBlas)

1. 검증 유형 및 실험 환경 (Validation Type & Setup)

본 실증 검증은 C++ CPU 구현체 대비 단계별 CUDA 최적화 버전의 연산 시간(Execution Latency), 메모리 오버헤드, 정밀도 일치 여부를 측정하는 정량적 벤치마크(Quantitative Benchmark) 및 프로파일링(Profiling)으로 수행되었다.

- 실험 환경: NVIDIA GPU (CUDA 12.x, nvcc 컴파일러, cuBLAS 12.x, cuSPARSE 지원), Ubuntu Linux x86_64.
- 프로파일링 도구: NVIDIA Nsight Systems (nsys), 고해상도 타이머(std::chrono / cudaEvent).

2. 실증 데이터 및 벤치마크 결과 (Empirical Evidence)

단계별 최적화에 따른 CROWN Backward Iteration 실행 시간 측정 결과:

구현 버전	주요 기법	실행 시간 (Latency)	CPU 대비 속도비
Base (CPU Only)	기존 C++ 배열 순차 연산	101.0 ms	1.0x (기준)
v1 (Initial GPU)	단순 커널 변환 (cudaMalloc 반복)	353.0 ms	0.28x (오히려 지연)
v2 (cuBLAS matmul)	행렬곱 GPU 오프로딩 (cublasDgemm)	201.6 ms	0.50x
v3 (cuSPARSE spMM)	희소 행렬 연산 및 0 생략 최적화	85.0 ms	1.18x (가속 시작)
v4 (Memory Pool)	사전 할당 메모리 풀 + 최적화 커널	40.0 ms	2.52x (최대 성능)
v5 (대규모 40,000차원)	Nsight System 프로파일링 체크 분할	580.0 ms	CPU(5,200ms) 대비 8.96x

3. 검증된 속성 (Verified Properties)

- 수학적 정합성 검증: CPU 버전과 GPU 버전이 출력한 Upper/Lower Bound 수치가 오차 $1e-12$ 이내로 완벽히 일치함을 self_test_relaxations 및 XOR 데모에서 확인.
- 메모리 풀의 효과 입증: 반복 메모리 할당 제거로 초기 GPU 버전 대비 지연시간을 353ms에서 40ms로 88.6% 단축 달성.
- 고차원 확장성 입증: 40,000x40,000 대규모 행렬에서 CPU 대비 약 9배의 압도적인 Throughput 향상 확인.

4. 식별된 제약 사항 및 한계점 (Limitations & Troubleshooting)

- Host-to-Device 복사 병목: Nsight Systems 타임라인 분석 결과, 소규모 신경망에서는 cudaMemcpy 오버헤드가 전체 연산의 60% 이상을 차지함.

- cuSPARSE 유효 임계값: 행렬의 희소도(Sparsity)가 70% 이하인 레이어에서는 cuSPARSE보다 cuBLAS가 더 우수한 성능을 보임.
- 추천 후속 과제: Unified Memory 및 커널 퓨전(Kernel Fusion) 기법을 통한 메모리 전송 횟수 감축 검증 필요.